Politechnika Wrocławska

Wydział Matematyki
Kierunek studiów: Matematyka stosowana
Specjalność: –

Praca dyplomowa – inżynierska

KLASYFIKACJA TRAJEKTORII SKALOWANEGO RUCHU BROWNA ZE STAŁYM I ZMIENNYM WSPÓŁCZYNNIKIEM Z WYKORZYSTANIEM METOD UCZENIA MASZYNOWEGO

Natalia Przewdzięk

słowa kluczowe:
skalowany ruch Browna, dyfuzja anomalna, losowy wykładnik dyfuzji, uczenie maszynowe, klasyfikacja trajektorii, symulacje numeryczne, procesy stochastyczne

krótkie streszczenie:
Praca dotyczy klasyfikacji trajektorii skalowanego ruchu Browna ze stałym oraz losowym wykładnikiem anomalnej dyfuzji z wykorzystaniem metod uczenia maszynowego. Celem jest ocena skuteczności metod klasyfikacyjnych w rozróżnianiu trajektorii generowanych przez procesy SBM i SBMRE. Przeprowadzono symulacje numeryczne dla różnych scenariuszy parametrów. Wyniki potwierdziły możliwość identyfikacji procesów z losowo zmiennym wykładnikiem dyfuzji.

Opiekun pracy dyplomowej	dr hab. inż. Agnieszka Wyłomańska	.....	.....
	Tytuł/stopień naukowy/imię i nazwisko	ocena	podpis

*Do celów archiwalnych pracę dyplomową zakwalifikowano do:**

a) kategorii A (akta wieczyste)

b) kategorii BE 50 (po 50 latach podlegające ekspertyzie)

** niepotrzebne skreślić*

pieczątka wydziałowa

Wrocław, rok 2025

Wrocław University
of Science and Technology

Faculty of Pure and Applied Mathematics
Field of study: Applied Mathematics
Specialty: –

Engineering Thesis

CLASSIFICATION OF SCALED BROWNIAN MOTION TRAJECTORIES WITH CONSTANT AND RANDOM COEFFICIENTS USING MACHINE LEARNING METHODS

Natalia Przewdzięk

keywords:
scaled Brownian motion, anomalous diffusion, random diffusion exponent, machine learning, trajectory classification, numerical simulations, stochastic processes

short summary:
The thesis focuses on the classification of scaled Brownian motion trajectories with constant and random anomalous diffusion exponents using machine learning methods. The objective is to assess the effectiveness of classification methods in distinguishing trajectories generated by SBM and SBMRE stochastic processes. Numerical simulations were conducted for various parameter scenarios. The results confirm the feasibility of identifying processes with randomly varying diffusion exponents.

Supervisor	dr hab. inż. Agnieszka Wyłomańska	.....	.....
	Title/degree/name and surname	grade	signature

*For the purposes of archival thesis qualified to:**

a) category A (perpetual files)

b) category BE 50 (subject to expertise after 50 years)

** delete as appropriate*

stamp of the faculty

Wrocław, 2025

Spis treści

Wstęp **3**

1 Metodologia: skalowany ruch Browna ze stałym i losowym parametrem **5**
1.1 Skalowany ruch Browna 5
1.1.1 Definicja procesu 5
1.1.2 Rozkład i własności probabilistyczne 6
1.1.3 Procedura symulacji i wizualizacja wyników 7
1.2 Skalowany ruch Browna z losowym wykładnikiem 9
1.2.1 Definicja procesu 9
1.2.2 Rozkład i własności ogólne 9
1.2.3 Przypadki szczególne rozkładu $\mathcal{A}$ 10
1.2.4 Procedura symulacji i wizualizacja wyników 11

2 Metoda rozróżniania procesów SBM i SBMRE **15**
2.1 Wybrane cechy skalowanego ruchu Browna i jego uogólnienia 15
2.1.1 Miary dynamiki procesu 15
2.1.2 Miary kształtu rozkładu 19
2.1.3 Podsumowanie wyboru cech 24
2.2 Architektura klasyfikatora i procedura uczenia 25
2.2.1 Przygotowanie danych do klasyfikacji 25
2.2.2 Architektura sieci neuronowej 26
2.2.3 Procedura uczenia 26
2.2.4 Wyniki klasyfikacji dla modelu głównego 26
2.2.5 Modele porównawcze 31
2.2.6 Podsumowanie 32

3 Analiza danych symulowanych **33**
3.1 Wpływ długości trajektorii 33
3.2 Wpływ wartości wykładnika dyfuzji 35
3.3 Wpływ rodzaju losowości wykładnika w SBMRE 37
3.4 Wpływ kroku czasowego 40
3.5 Podsumowanie 41

Podsumowanie **43**

Bibliografia **44**

Wstęp

Zjawiska dyfuzji odgrywają fundamentalną rolę w opisie losowego ruchu w wielu dziedzinach nauki, takich jak fizyka statystyczna, biologia, hydrologia czy analiza danych ekonomicznych. Klasyczny model dyfuzji, oparty na ruchu Browna, zakłada liniowy wzrost średniego kwadratu przemieszczenia w czasie, co odpowiada tzw. dyfuzji normalnej [2, 27, 31]. W licznych zastosowaniach empirycznych założenie to okazuje się jednak niewystarczające. Obserwacje prowadzone w układach złożonych i niejednorodnych wskazują na występowanie dyfuzji anomalnej, charakteryzującej się nieliniową zależnością średniego kwadratu przemieszczenia od czasu [6, 28].

Dyfuzja anomalna opisywana jest zazwyczaj za pomocą potęgowego prawa wzrostu drugiego momentu, w którym kluczową rolę odgrywa wykładnik dyfuzji. W zależności od jego wartości wyróżnia się procesy subdyfuzyjne oraz superdyfuzyjne [6]. Modele anomalnej dyfuzji znalazły szerokie zastosowania m.in. w opisie transportu w komórkach biologicznych, ruchu cząstek w ośrodkach porowatych, dynamiki rynków finansowych oraz analizy sygnałów [13, 21, 28].

Wśród gaussowskich modeli anomalnej dyfuzji szczególne znaczenie mają ułamkowy ruch Browna oraz skalowany ruch Browna. Ułamkowy ruch Browna, oparty na ideach samopodobieństwa procesów gaussowskich rozwijanych m.in. przez Kołmogorowa [20], został sformalizowany przez Mandelbrota i van Nessa [4, 25, 36]. Proces ten cechuje się długozasięgowymi korelacjami przyrostów i znajduje zastosowanie m.in. w hydrologii, biologii oraz ekonomii. Z kolei skalowany ruch Browna stanowi markowowski model anomalnej dyfuzji, w którym niestacjonarność przyrostów wynika z deterministycznej zmiany skali czasowej [15, 23].

Skalowany ruch Browna był przedmiotem licznych badań teoretycznych, obejmujących m.in. analizę własności ekstremalnych, transformacje czasowe oraz związki z procesami losowymi typu CTRW [24, 35]. Szczególną uwagę poświęcono również zagadnieniom łamania ergodyczności oraz zachowaniu czasowo uśrednionych statystyk, takich jak czasowo uśrednione przemieszczenie średniokwadratowe [30, 34], a także alternatywnych miar opartych na strukturze autokowariancji przyrostów, umożliwiających bardziej szczegółową charakterystykę dyfuzji anomalnej [22].

Rozwój nowoczesnych technik eksperymentalnych, w szczególności metod śledzenia pojedynczych cząstek, ujawnił jednak istotne ograniczenia klasycznych modeli anomalnej dyfuzji z ustalonymi parametrami. W wielu eksperymentach biologicznych obserwuje się, że wykładnik dyfuzji nie jest stały, lecz zmienia się losowo pomiędzy poszczególnymi trajektoriami, mimo że pochodzą one z tego samego układu fizycznego [9, 28]. Zjawisko to doprowadziło do rozwoju modeli z losowymi parametrami, wpisujących się w nurt superstatystyki oraz modeli dyfuzji z losowymi parametrami. [3, 7].

Jednym z takich uogólnień jest skalowany ruch Browna z losowym wykładnikiem dyfuzji, zaproponowany i szczegółowo przeanalizowany w pracy [37]. Model ten zachowuje podstawowe własności skalowanego ruchu Browna na poziomie pojedynczych trajektorii,

jednocześnie uwzględniając losową zmienność wykładnika dyfuzji pomiędzy realizacjami procesu. Wykazano, że losowość tego parametru prowadzi do istotnych zmian w zachowaniu średnich kwadratów przemieszczenia, czasowo uśrednionych statystyk oraz parametrów łamania ergodyczności [8].

Celem niniejszej pracy jest wykorzystanie metod uczenia maszynowego do klasyfikacji trajektorii skalowanego ruchu Browna ze stałym oraz losowym wykładnikiem anomalnej dyfuzji. W tym celu analizie poddano trajektorie generowane przez model skalowanego ruchu Browna oraz jego uogólnienie z losowym wykładnikiem dyfuzji, rozważając różne scenariusze rozkładów parametru anomalii dyfuzji. Skuteczność zaproponowanego podejścia oceniono w zadaniu rozróżniania badanych procesów.

W pracy wykorzystano wybrane wielkości opisujące dynamikę trajektorii, takie jak czasowo uśrednione przesunięcie średniokwadratowe oraz zdetrendowaną średnią ruchomą, które są powszechnie stosowane w analizie procesów anomalnej dyfuzji [28]. Uzupełniono je miarami opisującymi kształt rozkładu wartości procesu. Na podstawie tak skonstruowanego opisu trajektorii zbudowano model klasyfikacyjny i przeprowadzono analizę jego skuteczności w rozróżnianiu trajektorii badanych procesów.

Praca składa się z trzech rozdziałów oraz podsumowania. W rozdziale pierwszym wprowadzono pojęcie skalowanego ruchu Browna ze stałym wykładnikiem dyfuzji oraz jego uogólnienie z losowym wykładnikiem. Przedstawiono definicje obu procesów, ich podstawowe własności probabilistyczne, rozkłady wartości procesu w ustalonej chwili czasu oraz procedury symulacji numerycznej. Omówiono również wpływ losowości wykładnika dyfuzji na zachowanie procesu, ilustrując różnice pomiędzy badanymi procesami na podstawie przykładowych trajektorii oraz odpowiadających im rozkładów wartości.

Rozdział drugi poświęcono analizie charakterystyk procesu służących do rozróżniania trajektorii skalowanego ruchu Browna. Przedstawiono miary opisujące dynamikę procesu oraz kształt rozkładu wartości, a następnie zbudowano na ich podstawie zestaw wielkości wejściowych wykorzystywanych w modelu klasyfikacyjnym opartym na sieci neuronowej. Omówiono architekturę klasyfikatora, procedurę uczenia oraz szczegółowo przeanalizowano uzyskane wyniki klasyfikacji dla różnych wariantów zadania.

W rozdziale trzecim przeprowadzono analizę danych symulowanych, której celem było zbadanie wpływu parametrów symulacji na zachowanie wybranych charakterystyk procesu. Przeanalizowano wpływ długości trajektorii, wartości wykładnika dyfuzji, rodzaju jego losowości oraz kroku czasowego na stabilność i zmienność estymatorów. Uzyskane wyniki pozwoliły na pogłębioną interpretację skuteczności metod rozróżniania badanych procesów oraz ocenę ograniczeń wynikających z charakteru danych.

Pracę zamyka podsumowanie, w którym zestawiono najważniejsze wnioski wynikające z przeprowadzonych analiz.

Rozdział 1

Metodologia: skalowany ruch Browna ze stałym i losowym parametrem

Procesy dyfuzyjne opisują rozprzestrzenianie się cząstek w czasie i przestrzeni. W klasycznym ruchu Browna wariancja rośnie liniowo w czasie, co odpowiada tzw. normalnej dyfuzji. W wielu rzeczywistych układach - m.in. w materiałach porowatych, środowiskach biologicznych czy układach o zmiennej temperaturze - obserwuje się jednak zachowania odbiegające od tej klasycznej zależności. Zjawiska te określa się mianem *anomalii dyfuzyjnych* [6, 28]. W zależności od tempa wzrostu wariancji wyróżnia się:

- **subdyfuzję** – gdy rozrzut rośnie wolniej niż liniowo,
- **superdyfuzję** – gdy rozrzut rośnie szybciej niż liniowo.

Taki podział procesów dyfuzyjnych na subdyfuzyjne i superdyfuzyjne jest standardowy w literaturze dotyczącej dyfuzji anomalnej [15, 28].

W tej części pracy przedstawiono dwa modele służące do opisu zjawisk anomalii dyfuzyjnych: skalowany ruch Browna ze stałym wykładnikiem dyfuzji oraz jego uogólnienie z wykładnikiem losowym, które są często stosowane w literaturze do modelowania procesów o niestacjonarnej dynamice [15, 37]. Najpierw omówiony zostaje skalowany ruch Browna ze stałym parametrem α, w szczególności jego definicja, własności rozkładów oraz procedura symulacji. Następnie przedstawiony zostaje model skalowanego ruchu Browna z losowym wykładnikiem $\mathcal{A}$, którego losowość prowadzi do istotnie odmiennych własności procesu. Dla obu modeli zaprezentowano również przykłady trajektorii oraz rozkładów wartości procesu w ustalonej chwili czasu, co umożliwia ilustrację teoretycznych różnic pomiędzy tymi dwiema klasami procesów.

1.1 Skalowany ruch Browna

W pierwszym etapie analizie poddany zostaje skalowany ruch Browna ze stałym parametrem α. Poniżej przedstawiono jego definicję oraz podstawowe własności, które będą punktem odniesienia dla modelu z losowym wykładnikiem.

1.1.1 Definicja procesu

W modelowaniu zjawisk anomalii dyfuzyjnych, czyli procesów, w których rozrzut cząstek nie zwiększa się liniowo w czasie, powszechnie stosuje się uogólnienia klasycznego ruchu Browna.

Jednym z najprostszych i najczęściej analizowanych modeli tego typu jest **skalowany ruch Browna** (ang. *Scaled Brownian Motion*, SBM), w którym efekt anomalii uzyskuje się poprzez przeskalowanie czasu w standardowym procesie Wienera [15, 30].

Definicja 1.1 (Skalowany ruch Browna [15, 37])**.** Proces skalowanego ruchu Brwona definiowany jest zależnością:

$$B_\alpha(t) = B(t^\alpha), \quad t \geq 0,\ \alpha > 0, \tag{1.1}$$

gdzie $B(t)$ oznacza standardowy ruch Browna (proces Wienera) spełniający $B(0) = 0$, $E[B(t)] = 0$ oraz $Var[B(t)] = t$.

Parametr α jest dodatnim współczynnikiem skalującym czas i określa charakter obserwowanej dyfuzji:

- $\alpha < 1$ – subdyfuzja odpowiadająca wolniejszemu rozprzestrzenianiu się cząsteczek,
- $\alpha = 1$ – normalna dyfuzja, czyli klasyczny ruch Browna,
- $\alpha > 1$ – superdyfuzja, w której cząstka porusza się szybciej niż w przypadku klasycznego ruchu.

Taki podział na przypadki subdyfuzyjne, normalne i superdyfuzyjne jest standardowy w literaturze dotyczącej dyfuzji anomalnej [6, 28]. Parametr α stanowi zatem kluczowy czynnik kształtujący dynamikę procesu, umożliwiając opis zarówno sub-, jak i superdyfuzyjnych zachowań.

1.1.2 Rozkład i własności probabilistyczne

Proces skalowanego ruchu Browna jest procesem gaussowskim, czyli takim, dla którego każdy skończony zbiór $(B_\alpha(t_1), B_\alpha(t_2), ..., B_\alpha(t_n))$ ma wielowymiarowy rozkład normalny [15, 30]. Wynika z tego, że dla każdego ustalonego $t > 0$ zmienna losowa $B_\alpha(t)$ ma rozkład normalny o wartości oczekianej 0 i wariancji t^α:

$$B_\alpha(t) \sim \mathcal{N}(0, t^\alpha). \tag{1.2}$$

Gęstość prawdopodobieństwa procesu SBM dla ustalonego $t > 0$ ma postać:

$$f_{B_\alpha(t)}(x) = \frac{1}{\sqrt{2\pi\, t^\alpha}} \exp\left(-\frac{x^2}{2t^\alpha}\right), \tag{1.3}$$

co oznacza, że kształt rozkładu zachowuje symetrię względem zera, a jego rozproszenie zależy od parametru α oraz czasu t. Wzrost wartości α powoduje spłaszczenie krzywej gęstości i zwiększenie rozrzutu trajektorii, natomiast mniejsze wartości α prowadzą do jej większego skupienia wokół środka.
Podstawowe charakterystyki procesu mają postać:

- wartość oczekiwana: $E[B_\alpha(t)] = 0$,
- wariancja: $Var[B_\alpha(t)] = E[B_\alpha^2(t)] = t^\alpha$,
- kowariancja dla $s, t > 0$:

$$Cov(B_\alpha(s), B_\alpha(t)) = \min(s^\alpha, t^\alpha). \tag{1.4}$$

Kowariancja zależna od czasu wskazuje, że przyrosty procesu są niestacjonarne, co oznacza, że ich wariancja zmienia się wraz z położeniem w czasie. Jednoczesnie proces zachowuje niezależność przyrostów wynikającą z definicji $B_\alpha(t) = B(t^\alpha)$. Własności te odróżniają SBM od frakcjonalnego ruchu Browna i były szczegółowo analizowane m.in. w [15, 30]. Proces $B_\alpha(t)$ posiada następujące własności:

- jest **gaussowski** – wszystkie rozkłady mają postać normalną,
- jest **samopodobny** z wykładnikiem $H = \alpha/2$ [15], tj.

$$B_\alpha(ct) \stackrel{d}{=} c^H B_\alpha(t), \tag{1.5}$$

- jest **procesem Markowskim** o **niestacjonarnych przyrostach**.

Własności te sprawiają, że jest jednym z najprostszych modeli opisujących anomalną dyfuzję. Zachowuje on strukturę procesu Browna, lecz wprowadza kontrolowaną niestacjonarność przyrostów, dzięki czemu umożliwia modelowanie zarówno sub-, jak i subdyfuzyjnych zachowań.

1.1.3 Procedura symulacji i wizualizacja wyników

W literaturze proces skalowanego ruchu Browna opisywany jest nie tylko przez definicję $B_\alpha(t) = B(t^\alpha)$, lecz także jako rozwiązanie równania stochastycznego z czasowo zmiennym współczynnikiem dyfuzji ([15, 37]):

$$dX(t) = \sqrt{\alpha\, t^{\alpha-1}}\, dW(t), \qquad X(0) = 0. \tag{1.6}$$

Zastosowanie schematu Euler–Maruyama jest standardowym podejściem w symulacjach procesów stochastycznych tego typu [17]. Równanie (1.6) prowadzi do wariancji $Var[X(t)] = t^\alpha$, zgodnej z własnościami procesu $B_\alpha(t)$. W dalszej części korzystając z tego zapisu aproksymowane jest rozwiązanie za pomocą schematu Euler-Maruyama.

Uwaga 1.2 (Algorytm symulacji procesu SBM)**.**

1. Ustal długość trajektorii T, krok Δt oraz liczbę punktów $N = \frac{T}{\Delta t}$.
2. Zdefiniuj siatkę czasów:
$$t_i = i\Delta t, \quad i = 0, 1, \ldots, N.$$
3. Wyznacz współczynnik wzmocnienia (dyfuzji):
$$g(t_i) = \sqrt{\alpha\, t_i^{\alpha-1}}.$$
4. Generuj przyrosty procesu Wienera:
$$\Delta W_i \sim \mathcal{N}(0,\, \Delta t),$$
a następnie skonstruuj trajektorię:
$$X_{i+1} = X_i + g(t_i)\Delta W_i, \qquad X_0 = 0.$$

5. Symulację powtarzaj dla wybranych wartości α (np. $\alpha = 0.6$, 1.0, 1.4), aby porównać zachowanie sub-, normalnej i superdyfuzji.

Wykorzystanie schematu Euler-Maruyama pozwala w kontrolowany sposób aproksymować proces skalowanego ruchu Browna, a tym samym badać jego własności w zależności od wartości parametru α. W celu oceny poprawności implementacji oraz uzyskania intuicyjnego obrazu zachowania procesu przeprowadzono wizualną analizę wyników symulacji. Uwzględnia ona zarówno przebieg generowanych ścieżek, jak i rozkłady wartości procesu w wybranej chwili czasu, co pozwala zestawić obserwacje numeryczne z przewidywaniami wynikającymi z własności teoretycznych modelu.

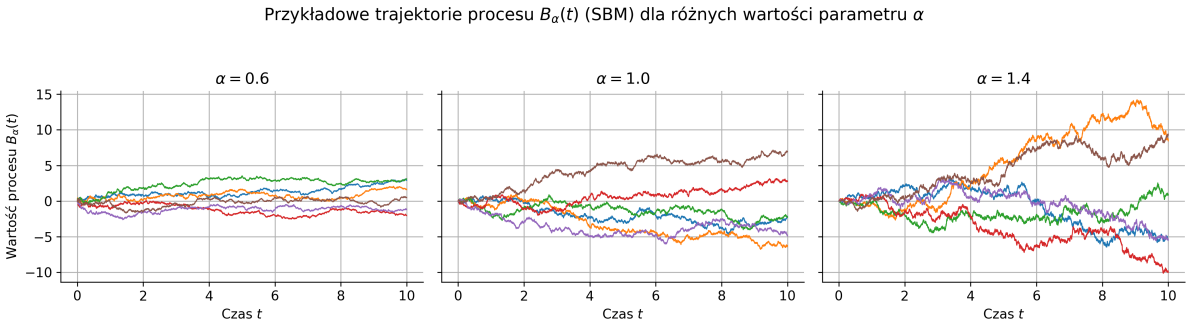

Rysunek 1.1: Przykładowe trajektorie skalowanego ruchu Browna dla różnych wartości parametru α.

Wygenerowane trajektorie ukazują, w jaki sposób zmienia się charakter ruchu wraz ze wzrostem lub spadkiem parametru α. Dla wartości $\alpha = 0{,}6$ przebiegi są wyraźnie bardziej „skupione” wokół zera, co odpowiada wolniejszemu wzrostowi wariancji typowemu dla subdyfuzji. Dla $\alpha = 1{,}4$ widoczny jest natomiast znacznie większy rozrzut trajektorii, zgodnie z przyspieszoną dynamiką superdyfuzyjną. Zestawienie sześciu niezależnych realizacji dla każdej wartości parametru, przedstawione w trzech panelach Rys. 1.1, dobrze ilustruje wpływ parametru α na dynamikę procesu. Zaobserwowane różnice są zgodne z teoretycznymi własnościami skalowanego ruchu Browna, w szczególności z nieliniowym wzrostem wariancji w czasie $Var[B_\alpha(t)] = t^\alpha$ [15].

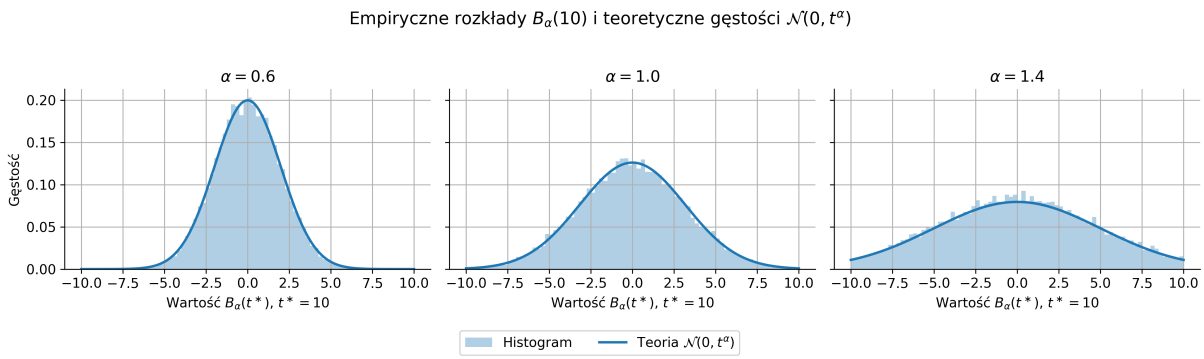

Rysunek 1.2: Gęstości rozkładu $B_\alpha(t^*)$ dla ustalonego czasu $t^* = 10$ i różnych wartości α.

Drugim elementem analizy jest porównanie rozkładów wartości procesu w ustalonej chwili czasu. Histogramy zaprezentowane na Rys. 1.2 przedstawiają empiryczne rozkłady

$B_\alpha(10)$, uzyskane na podstawie 20 000 niezależnych realizacji procesu, zestawione z odpowiadającymi im gęstościami teoretycznymi $\mathcal{N}(0, t^\alpha)$ wynikającymi ze wzoru (1.3). Wzrost parametru α prowadzi do zwiększenia wariancji 10^α, co skutkuje szerszymi rozkładami dla większych wartości α. Zauważalna zgodność empirycznych histogramów z krzywymi teoretycznymi potwierdza poprawność przeprowadzonych symulacji oraz zgodność wyników numerycznych z własnościami probabilistycznymi procesu SBM, opisanymi w literaturze jako rozkłady normalne o wariancji zależnej od czasu [30, 37].

1.2 Skalowany ruch Browna z losowym wykładnikiem

W kolejnym etapie analizie poddany zostaje skalowany ruch Browna z losowym wykładnikiem dyfuzji. Model ten stanowi uogólnienie przypadku ze stałym parametrem i pozwala opisać sytuacje, w których intensywność dyfuzji zmienia się pomiędzy realizacjami procesu, co jest charakterystyczne dla środowisk heterogenicznych [37]. Poniżej przedstawiono jego definicję oraz własności rozkładów wynikające z losowości wykładnika $\mathcal{A}$.

1.2.1 Definicja procesu

Skalowany ruch Browna z losowym wykładnikiem (ang. *Scaled Brownian Motion with Random Exponent*, SBMRE) stanowi uogólnienie klasycznego modelu SBM, w którym parametr skalujący czas nie jest stały, lecz podlega losowej zmienności. Konstrukcja ta pozwala opisać zjawiska, w których tempo dyfuzji nie jest jednorodne, lecz wynika z niepewności lub heterogeniczności środowiska.

Definicja 1.3 (Skalowany ruch Browna z losowym wykładnikiem [37])**.** Niech $\mathcal{A}$ będzie dodatnią zmienną losową o gęstości $f_\mathcal{A}(\alpha)$, niezależną od standardowego ruchu Browna $B(t)$. Proces SBMRE definiuje się jako:

$$B_\mathcal{A}(t) = B\left(t^\mathcal{A}\right), \qquad t \geq 0. \tag{1.7}$$

Losowy wykładnik $\mathcal{A}$ pełni rolę losowego parametru modelu i sprawia, że każda trajektoria jest realizacją procesu SBM z inną, wylosowaną wartością wykładnika α. Warunkowo względem $\mathcal{A} = \alpha$ otrzymywany jest klasyczny model SBM, natomiast rozkład marginalny procesu jest mieszaniną takich modeli. W efekcie SBMRE opisuje dyfuzję w ośrodkach o niejednornej dynamice, gdzie różne realizacje procesu charakteryzują się odmiennym tempem rozprzestrzeniania [37].

1.2.2 Rozkład i własności ogólne

Proces $B_\mathcal{A}(t)$ jest warunkowo gaussowski, ponieważ dla ustalonej wartości wykładnika $\mathcal{A} = \alpha$ sprowadza się do klasycznego skalowanego ruchu Browna, czyli:

$$(B_\mathcal{A}(t) \,|\, \mathcal{A} = \alpha) \sim \mathcal{N}(0,\, t^\alpha)\,. \tag{1.8}$$

Ponieważ jednak wykładnik $\mathcal{A}$ jest zmienną losową, rozkład procesu $B_\mathcal{A}(t)$ w ustalonej chwili czasu jest mieszaniną rozkładów normalnych o różnych wariancjach.

Fakt 1.4 (Rozkład w ustalonej chwili czasu dla procesu SBMRE [37])**.** *Dla każdego $t > 0$ gęstość zmiennej losowej $B_\mathcal{A}(t)$ wyraża się wzorem:*

$$f_{B_\mathcal{A}(t)}(x) = \int_0^\infty \frac{1}{\sqrt{2\pi\, t^\alpha}} \exp\left(-\frac{x^2}{2t^\alpha}\right) f_\mathcal{A}(\alpha)\, d\alpha, \tag{1.9}$$

gdzie $f_{\mathcal{A}}$ oznacza gęstość rozkładu wykładnika $\mathcal{A}$. Otrzymana gęstość powstaje jako mieszanina rozkładów normalnych, w której każdy składnik jest ważony gęstością $f_{\mathcal{A}}$.

Własności drugiego rzędu procesu wynikają bezpośrednio z własności momentów zmiennej losowej $\mathcal{A}$. Definiując funkcję tworzącą momenty:

$$M_{\mathcal{A}}(u) = \mathbb{E}\Big[u^{\mathcal{A}}\Big], \qquad u > 0. \tag{1.10}$$

otrzymujemy:

$$\mathbb{E}\Big[B_{\mathcal{A}}(t)\Big] = 0, \qquad \mathbb{E}\Big[B_{\mathcal{A}}^2(t)\Big] = M_{\mathcal{A}}(t). \tag{1.11}$$

Proces SBMRE zachowuje część własności skalowanego ruchu Browna jedynie warunkowo. Dla ustalonego wykładnika $\mathcal{A} = \alpha$ proces jest gaussowski, Markowski i posiada niezależne przyrosty. Jednak po uśrednieniu względem rozkładu $\mathcal{A}$ własności te zanikają. W szczególności:

- proces nie jest gaussowski (jest mieszaniną rozkładów normalnych),
- przyrosty tracą własność niezależności, gdyż są sprzężone poprzez losowy wykładnik $\mathcal{A}$, wspólny dla całej trajektorii,
- proces nie jest Markowski, ponieważ informacja o rozkładzie $\mathcal{A}$ przenosi zależności pomiędzy chwilami,
- zachowana zostaje niestacjonarność przyrostów (jak w SBM),
- samopodobność zachodzi jedynie warunkowo względem wartości wykładnika $\mathcal{A}$, natomiast zanika po uwzględnieniu jego losowości.

Utrata tych własności po uśrednieniu względem losowego wykładnika jest charakterystyczna dla modeli dyfuzji z losowymi parametrami i została szczegółowo przeanalizowana w kontekście procesu SBMRE w [37]. Zjawisko to odzwierciedla dyfuzję w środowisku heterogenicznym, w którym rzeczywisty wykładnik skalowania ulega zmienności od trajektorii do trajektorii.

1.2.3 Przypadki szczególne rozkładu $\mathcal{A}$

W zależności od zastosowania zmienna losowa $\mathcal{A}$ może mieć różne rozkłady, co prowadzi do odmiennych własności procesu SBMRE, a wybór konkretnego rozkładu zależy od charakteru modelowanego zjawiska. Poniżej omówiono trzy przykładowe rozkłady wykorzystywane w analizach numerycznych oraz literaturze.

Dwupunktowy rozkład wykładnika. Najprostszym i jednocześnie najczęściej analizowanym przypadkiem jest sytuacja, w której zmienna losowa $\mathcal{A}$ przyjmuje jedną z dwóch możliwych wartości:

$$\mathcal{A} = \begin{cases} \alpha_1, & \text{z prawdopodobieństwem } p, \\ \alpha_2, & \text{z prawdopodobieństwem } 1-p, \end{cases} \qquad 0 < \alpha_1 < \alpha_2. \tag{1.12}$$

Wówczas gęstość procesu SBMRE przyjmuje postać mieszaniny dwóch gęstości normalnych:

$$f_{B_{\mathcal{A}}(t)}(x) = p\, f_{\mathcal{N}(0,t^{\alpha_1})}(x) + (1-p)\, f_{\mathcal{N}(0,t^{\alpha_2})}(x), \tag{1.13}$$

co prowadzi do rozkładu o wyraźnie cięższych ogonach niż w przypadku czystego SBM. Model ten odzwierciedla sytuacje, w których populacja lub środowisko składa się z dwóch podgrup o różnych poziomach dyfuzji.

Rozkład jednostajny. Innym naturalnym wyborem jest rozkład jednostajny na przedziale $[\alpha_{\min}, \alpha_{\max}]$:

$$\mathcal{A} \sim \mathrm{U}(\alpha_{\min}, \alpha_{\max}), \qquad 0 < \alpha_{\min} < \alpha_{\max}, \tag{1.14}$$

z gęstością

$$f_{\mathcal{A}}(\alpha) = \frac{1}{\alpha_{\max} - \alpha_{\min}}, \qquad \alpha \in [\alpha_{\min}, \alpha_{\max}]. \tag{1.15}$$

W takim przypadku wszystkie wartości wykładnika w zadanym przedziale są jednakowo prawdopodobne, co odpowiada sytuacji, w której możliwe są różne „poziomy" anomalnej dyfuzji bez wyróżniania żadnego z nich. Mieszanka gęstości normalnych z wariancjami t^{α}, $\alpha \in [\alpha_{\min}, \alpha_{\max}]$, prowadzi do rozkładu szerszego niż w przypadku pojedynczego SBM, ale o mniej wyraźnym „dwumodalnym" charakterze niż dla rozkładu dwupunktowego.

Rozkład beta. W bardziej złożonych zastosowaniach stosuje się ciągłe rozkłady parametrów. Typowym przykładem jest rozkład beta na przedziale $(0, 1)$:

$$\mathcal{A}_0 \sim \mathrm{Beta}(a, b), \qquad a, b > 0, \tag{1.16}$$

z gęstością

$$f_{\mathcal{A}_0}(\alpha) = \frac{\alpha^{a-1}(1-\alpha)^{b-1}}{B(a, b)}, \qquad \alpha \in (0, 1). \tag{1.17}$$

Aby umożliwić modelowanie wykładnika dyfuzji na dowolnym przedziale $[A_1, A_2] \subset (0, \infty)$, wprowadza się przeskalowanie

$$\mathcal{A} = A_1 + (A_2 - A_1)\,\mathcal{A}_0. \tag{1.18}$$

Powstały w ten sposób rozkład beta na $[A_1, A_2]$ generuje mieszaninę gęstości normalnych o wariancjach t^{α} i umożliwia płynne modelowanie niejednorodności w intensywności dyfuzji. Rozwiązanie to odpowiada sytuacjom, w których parametr procesu zmienia się w sposób ciągły w obrębie populacji lub środowiska.

Wybór rozkładu $\mathcal{A}$ wpływa na kształt marginalnego rozkładu procesu. Rozkłady o większej wariancji generują bardziej zróżnicowane trajektorie oraz gęstości o cięższych ogonach. Rozkład dwupunktowy prowadzi do mieszaniny dwóch „typów" trajektorii, rozład jednostajny opisuje przypadek równomiernego rozrzutu możliwych wykładników, natomiast rozkład beta pozwala modelować bardziej złożone, asymetryczne rozkłady intensywności dyfuzji. Mieszaniny rozkładów normalnych, charakterystyczne dla SBMRE, stanowią naturalny opis dyfuzji w środowiskach heterogenicznych, zarówno w fizyce, jak i w zastosowaniach biologicznych oraz finansowych ([37]).

1.2.4 Procedura symulacji i wizualizacja wyników

Symulacja procesu SBMRE polega na połączeniu dwóch elementów: losowania wartości wykładnika $\mathcal{A}$ z przyjętego rozkładu oraz generowania trajektorii warunkowych, które dla ustalonego $\mathcal{A} = \alpha$ odpowiadają skalowanemu ruchowi Browna o wykładniku α. W ten sposób każda trajektoria jest realizacją procesu SBM o innym, losowym poziomie dyfuzji, co odzwierciedla heterogeniczność środowiska. Celem analizy wizualnej jest zobrazowanie różnic między SBM a SBMRE oraz ocena wpływu zmienności parametru na kształt trajektorii i rozkład wartości procesu.

Uwaga 1.5 (Algorytm symulacji SBMRE)**.**

1. Wylosuj wartości wykładnika

$$\alpha^{(1)}, \ldots, \alpha^{(n_{\text{paths}})} \sim f_{\mathcal{A}},$$

   zgodnie z przyjętym rozkładem $\mathcal{A}$ (np. dwupunktowym, jednostajnym lub beta).

2. Dla każdej trajektorii k zasymuluj proces SBM o wykładniku $\alpha^{(k)}$ za pomocą schematu Euler–Maruyama:

$$X_{i+1}^{(k)} = X_i^{(k)} + \sqrt{\alpha^{(k)}\, t_i^{\alpha^{(k)}-1}}\, \Delta W_i^{(k)}, \qquad \Delta W_i^{(k)} \sim \mathcal{N}(0, \Delta t).$$

3. Powtórz symulację dla wybranych rozkładów $\mathcal{A}$.

Taki schemat symulacji jest zgodny z podejściem stosowanym w analizach numerycznych procesu SBMRE [37].

Kolejnym krokiem jest analiza zachowania procesu na podstawie trajektorii symulowanych zgodnie z opisaną procedurą oraz odpowiadających im rozkładów jednoczasowych.

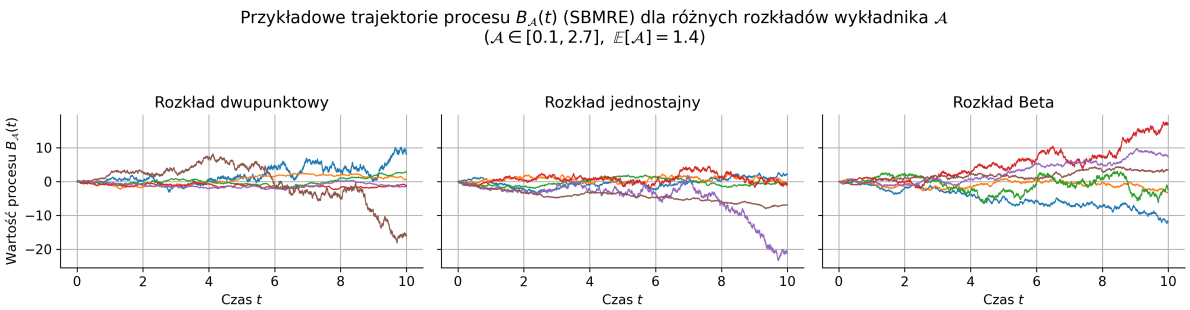

Rysunek 1.3: Przykładowe trajektorie procesu Browna z losowym parametrem dla trzech rozkładów wykładnika $\mathcal{A}$: dwupunktowego, jednostajnego oraz beta.

Wygenerowane trajektorie procesu SBMRE ukazują wpływ losowego wykładnika $\mathcal{A}$ na dynamikę dyfuzji. W każdym z trzech paneli Rys. 1.3 przedstawiono po sześć niezależnych realizacji odpowiadających różnym rozkładomparametru $\mathcal{A}$: dwupunktowemu, jednostajnemu oraz beta. Losowość wykładnika prowadzi do wyraźnie większego zróżnicowania przebiegów niż w przypadku klasycznego SBM. Dla rozkładu dwupunktowego obserwuje się mieszaninę ścieżek o dwóch charakterystycznych skalach dyfuzji, podczas gdy rozkład jednostajnydaje bardziej rozproszony obraz trajektorii. W przypadku rozkładu beta widoczna jestnajwiększa płynność zmian tempa dyfuzji, co odzwierciedla kształt gęstości $f_{\mathcal{A}}$. Zestawienie tych realizacji dobrze obrazuje, że zmienność parametru wpływa na dynamikę procesu w sposób istotnie silniejszy niż stała wartośćα w SBM.

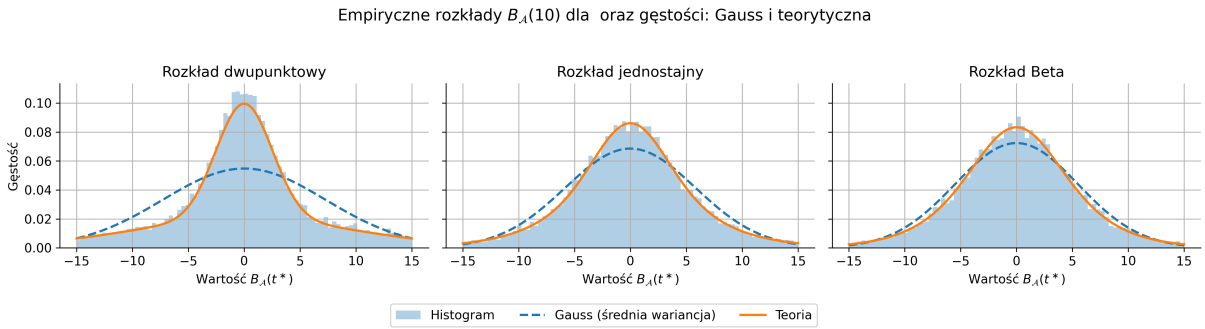

Rysunek 1.4: Gęstości rozkładu $B_{\mathcal{A}}(t^*)$ dla ustalonego czasu $t^* = 10$ oraz trzech rozkładów wykładnika $\mathcal{A}$, zestawione z teoretycznymi gęstościami mieszaninowymi wynikającymi ze wzoru (1.9).

Drugim elementem analizy jest porównanie jednoczasowych rozkładów wartości procesu. Histogramy przedstawione na Rys. 1.4 prezentują empiryczne rozkłady $B_{\mathcal{A}}(10)$ uzyskane na podstawie 20 000 niezależnych realizacji, zestawione z odpowiadającymi im gęstościami teoretycznymi wynikającymi z formuły mieszaninowej (1.9). W odróżnieniu od SBM, gdzie $B_\alpha(t)$ ma rozkład normalny, w SBMRE otrzymuje się mieszaninę rozkładów normalnych o wariancjach 10^α. Prowadzi to do rozkładów o szerszym zakresie oraz cięższych ogonach, a ich kształt jest ściśle zależny od wyboru rozkładu wykładnika $\mathcal{A}$. W przypadku rozkładu dwupunktowego widoczne są dwa dominujące zakresy wariancji, rozkład jednostajny prowadzi do bardziej jednolitego spłaszczenia, natomiast rozkład beta generuje łagodniejszy, bardziej płynny kształt wynikający z gęstości $f_{\mathcal{A}}$.

Zauważalna zgodność teoretycznych krzywych mieszaninowych z rozkładami empirycznymi potwierdza poprawność implementacji algorytmu symulacji oraz zgodność zachowania procesu SBMRE z jego modelem teoretycznym. Wyniki te podkreślają, że wprowadzenie losowego wykładnika prowadzi do istotnych zmian w strukturze marginalnych rozkładów procesu, mimo zachowania lokalnej, warunkowej względem $\mathcal{A}$, gaussowskości, co jest zgodne z własnościami opisanymi w literaturze [37].

Rozdział 2

Metoda rozróżniania procesów SBM i SBMRE

W niniejszym rozdziale przedstawiono metodę klasyfikacji trajektorii skalowanego ruchu Browna ze stałym wykładnikiem dyfuzji oraz skalowanego ruchu Browna z wykładnikiem losowym. Celem jest wskazanie cech pozwalających na skuteczne rozróżnienie obu modeli, a następnie zbudowanie i wytrenowanie klasyfikatora opartego na sieci neuronowej.

2.1 Wybrane cechy skalowanego ruchu Browna i jego uogólnienia

W pierwszej części rozdziału omówiono cechy procesów, które mogą służyć do ich rozróżniania. Analiza obejmuje zarówno własności pojedynczych trajektorii, jak i statystyki oparte na przyrostach oraz wybrane miary opisujące zmienność procesu w czasie. Szczególną uwagę położono na te wielkości, które następnie wykorzystano jako cechy wejściowe w modelu klasyfikacyjnym.

Wszystkie przedstawione w tej części wykresy wykonano dla jednego, ustalonego zestawu parametrów, wybranego w sposób reprezentatywny. Trajektorie generowano na przedziale czasowym $[0, 10]$ z krokiem $\Delta t = 10^{-3}$, co odpowiada 10 000 punktom czasowym. Dla każdego z analizowanych modeli wygenerowano 10 000 niezależnych realizacji procesu.

W przypadku procesu SBM zastosowano stały wykładnik dyfuzji $\alpha = 1.4$. Dla jego uogólnienia z wykładnikiem losowym rozważono trzy mechanizmy generowania parametru $\mathcal{A}$. W wariancie dwupunktowym wykładnik przyjmował naprzemiennie wartości 0.8 oraz 2.0 z jednakowym prawdopodobieństwem. W pozostałych przypadkach stosowano rozkład jednostajny oraz rozkład beta, które po odpowiednim przeskalowaniu miały nośnik w przedziale $[0.8, 2.0]$; dla rozkładu beta przyjęto parametry kształtu $a = b = 0.5$. Konstrukcja rozkładów zapewniała zachowanie tej samej wartości oczekiwanej wykładnika w każdym wariancie SBMRE, co umożliwia bezpośrednie zestawienie zachowania procesów SBM i SBMRE przy porównywalnym średnim tempie wzrostu.

2.1.1 Miary dynamiki procesu

W analizie trajektorii procesów anomalnej dyfuzji kluczową rolę odgrywają statystyki opisujące dynamikę zmienności sygnału w czasie. W niniejszym podrozdziale omówiono trzy miary wykorzystywane następnie jako cechy wejściowe w klasyfikacji trajektorii SBM

i SBMRE: przesunięcie średniokwadratowe (ang. *Mean Squared Displacement*, MSD), czasowo uśredniony MSD (ang. *Time-Averaged Mean Squared Displacement*, TAMSD) oraz zdetrendowaną średnią ruchomą (ang. *Detrended Moving Average*, DMA). Definicje i własności tych statystyk są zgodne z ujęciem przedstawionym w pracy [26].

Przesunięcie średniokwadratowe (MSD)

Dla procesu $X(t)$ przesunięcie średniokwadratowe definiuje się jako:

$$\mathrm{MSD}(t) = \mathbb{E}\Big[(X(t) - X(0))^2\Big]. \tag{2.1}$$

W przypadku skalowanego ruchu Browna o stałym wykładniku α zachodzi:

$$\mathrm{MSD}_{\mathrm{SBM}}(t) = t^{\alpha}. \tag{2.2}$$

Dla SBM z losowym wykładnikiem $\mathcal{A}$ mamy:

$$\mathrm{MSD}_{\mathrm{SBMRE}}(t) = \mathbb{E}\Big[t^{\mathcal{A}}\Big] = \int t^{\alpha} f_{\mathcal{A}}(\alpha)\, d\alpha. \tag{2.3}$$

Oznacza to, że średnia krzywa MSD dla SBMRE jest uśrednieniem funkcji potęgowych dla poszczególnych realizacji. Wynik ten jest zgodny z obserwacjami przedstawionymi w [26].

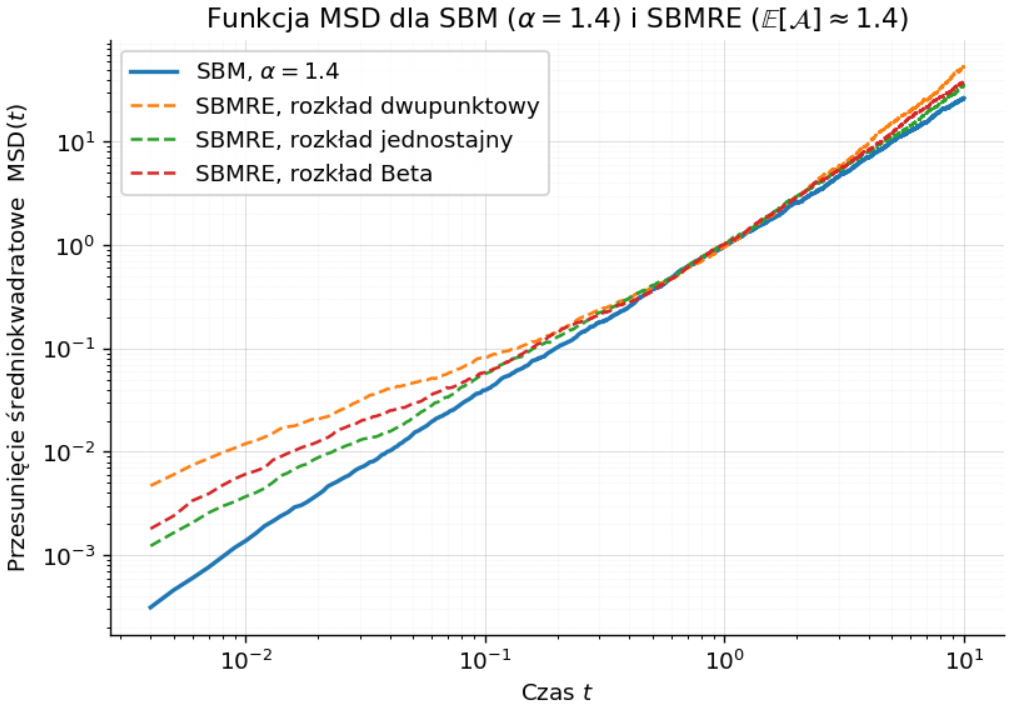

Rysunek 2.1: Funkcja MSD w skali log-log dla SBM ($\alpha = 1.4$) oraz SBMRE z różnymi rozkładami wykładnika anomalnego.

Na Rys. 2.1 przedstawiono funkcję MSD w skali log–log dla procesu SBM oraz jego uogólnienia SBMRE. Krzywa odpowiadająca SBM ma charakter prostoliniowy, co odzwierciedla deterministyczną zależność $\mathrm{MSD}(t) \sim t^{\alpha}$ przy stałym wykładniku $\alpha = 1.4$. W przypadku SBMRE, dla wszystkich rozpatrywanych rozkładów wykładnika dyfuzji, krzywe odbiegają od przebiegu SBM i wykazują charakterystyczne zakrzywienia.

Dla małych wartości czasu t funkcja MSD dla SBMRE przyjmuje wyższe wartości niż w przypadku SBM, ponieważ uśrednienie po rozkładzie $\mathcal{A}$ obejmuje również realizacje o większych wartościach wykładnika. Obecność takich trajektorii podnosi średnią przebiegu MSD względem modelu ze stałym parametrem. W pobliżu $t = 1$ krzywe SBMRE zbliżają się do przebiegu SBM, ponieważ dla $t = 1$ zachodzi równość $1^\alpha = 1$ dla dowolnego wykładnika α. W efekcie wszystkie warianty modelu, niezależnie od rozkładu $\mathcal{A}$, przyjmują w tym punkcie identyczną wartość MSD. Dla większych czasów obserwuje się ponowne odchylenie ku wyższym wartościom MSD, co prowadzi do delikatnie zakrzywionego profilu charakterystycznego dla procesów o losowym parametrze.

Choć MSD prawidłowo oddaje globalne skalowanie procesu, podobieństwo krzywych w otoczeniu $t = 1$ i ich ponowne rozbieganie dla większych czasów sprawiają, że statystyka ta, rozpatrywana samodzielnie, nie jest wystarczająco czuła, aby jednoznacznie odróżnić SBM od SBMRE.

Czasowo uśredniony MSD (TAMSD)

TAMSD dla trajektorii $\{X(i)\}_{i=1}^{n}$ definiuje się jako:

$$\overline{\delta^2(\tau)} = \frac{1}{n-\tau}\sum_{i=1}^{n-\tau}\Big(X(i+\tau) - X(i)\Big)^2. \tag{2.4}$$

Z pracy [26] wiadomo, że:

$$\mathbb{E}[\mathrm{TAMSD}_{\mathrm{SBM}}] = \frac{n^{\alpha+1} - \tau^{\alpha+1} - (n-\tau)^{\alpha+1}}{(n-\tau)(\alpha+1)}, \tag{2.5}$$

$$\mathbb{E}[\mathrm{TAMSD}_{\mathrm{SBMRE}}] = \frac{1}{n-\tau}\sum_{i=1}^{n-\tau}\Big(M_{\mathcal{A}}\big(\log(i+\tau)\big) - M_{\mathcal{A}}\big(\log i\big)\Big). \tag{2.6}$$

gdzie $M_{\mathcal{A}}$ jest funkcją tworzącą momenty zmiennej losowej $\mathcal{A}$.

Dla SBMRE TAMSD wykazuje znacznie większe zróżnicowanie między trajektoriami, co czyni tę statystykę bardzo czułą na losowość wykładnika.

Na Rys. 2.2 przedstawiono rozkład wartości statystyki TAMSD dla wybranego opóźnienia τ. W przypadku SBM boxplot jest wyraźnie wąski, co odzwierciedla niską zmienność między trajektorjami charakterystyczną dla procesu z ustalonym wykładnikiem. Dla SBMRE rozrzut wartości TAMSD jest znacznie większy, ponieważ statystyka ta bezpośrednio reaguje na różnorodność tempa wzrostu poszczególnych trajektorii wynikającą z losowości wykładnika $\mathcal{A}$. Efekt ten jest szczególnie widoczny dla rozkładu dwupunktowego, gdzie obecność dwóch odmiennych wartości α prowadzi do silniejszego rozproszenia statystyk.

Z uwagi na dużą wrażliwość na zmienność tempa wzrostu trajektorii, analiza TAMSD stanowi skuteczne narzędzie do rozróżniania SBM i SBMRE, zwłaszcza gdy jest stosowana dla kilku różnych wartości opóźnienia τ.

Zdetrendowana średnia ruchoma (DMA)

DMA definiuje się jako:

$$\mathrm{DMA}(\tau) = \frac{1}{n-\tau}\sum_{j=\tau}^{n}\Big(X(j) - \bar{X}_\tau(j)\Big)^2, \tag{2.7}$$

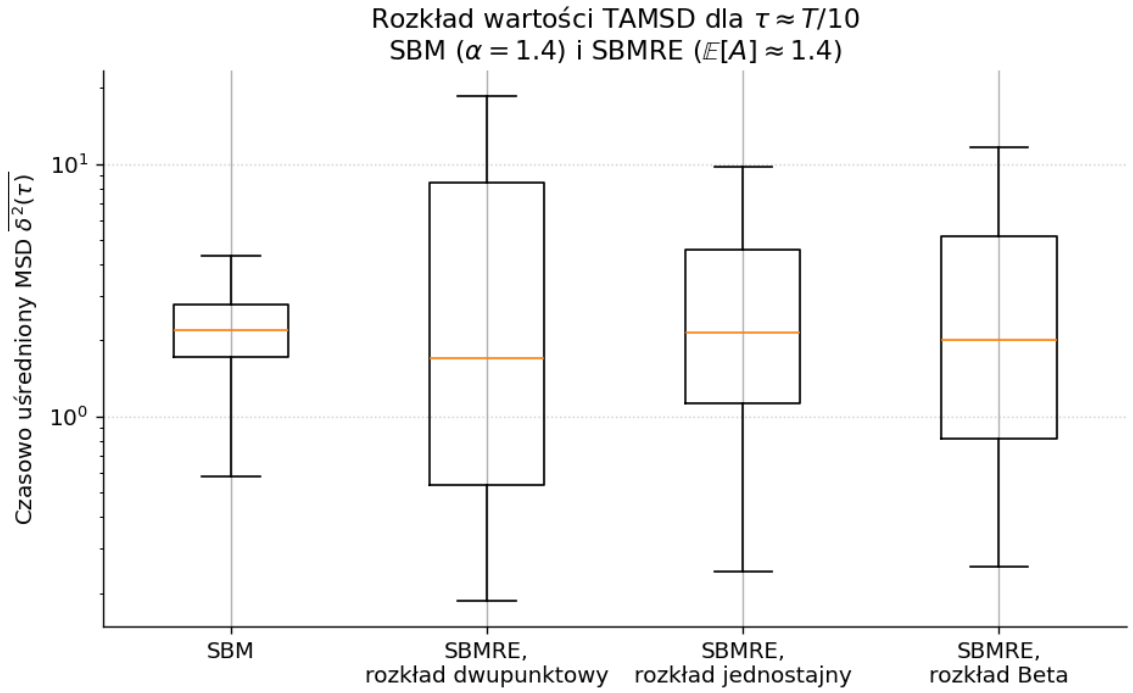

Rysunek 2.2: Rozkład wartości TAMSD dla $\tau \approx T/10$ dla SBM oraz SBMRE. Wartości przedstawiono w skali logarytmicznej na osi pionowej.

gdzie $\bar{X}_\tau(j)$ jest średnią ruchomą z okna długości τ.

Statystyka DMA mierzy odchylenie procesu od jego lokalnej średniej obliczanej w oknie długości τ. Ponieważ wartości tej miary zależą od lokalnych zmian tempa wzrostu trajektorii, jest ona szczególnie czuła na niejednorodność dynamiki charakterystyczną dla SBMRE.

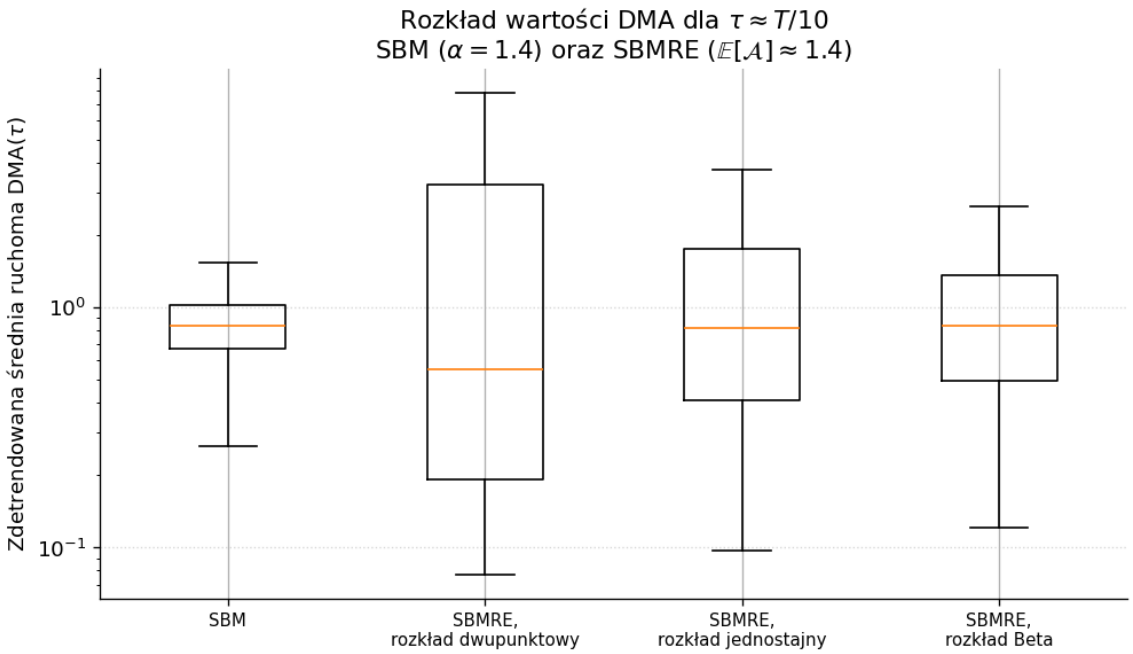

Rysunek 2.3: Rozkład wartości DMA dla $\tau \approx T/10$ dla SBM oraz SBMRE. Wartości przedstawiono w skali logarytmicznej na osi pionowej.

Na Rys. 2.3 przedstawiono rozkład wartości statystyki DMA dla wybranego opóźnienia τ. W przypadku SBM boxplot jest wyraźnie wąski, co wskazuje na niewielką zmienność tej statystyki pomiędzy różnymi trajektoriami i odzwierciedla jednorodną dynamikę procesu o stałym wykładniku. Dla SBMRE rozrzut wartości DMA jest znacznie większy, ponieważ miara ta reaguje na lokalne fluktuacje trajektorii wynikające z losowości wykładnika $\mathcal{A}$. Najsilniejszy efekt obserwuje się dla rozkładu dwupunktowego, gdzie połączenie dwóch odmiennych wartości α prowadzi do wyraźnego rozszerzenia rozkładu statystyki.

W przeciwieństwie do TAMSD, DMA jest szczególnie wrażliwa na krótkoskalowe zmiany krzywizny trajektorii, dlatego różnice pomiędzy SBM i SBMRE są tu jeszcze bardziej wyraźne. Zachowanie widoczne na wykresie jest spójne z charakterystyką dynamiki procesu SBMRE, gdzie zróżnicowanie lokalnego tempa wzrostu poszczególnych realizacji prowadzi do zwiększonej zmienności statystyki DMA. W rezultacie analiza DMA stanowi skuteczne narzędzie do odróżniania SBM i SBMRE.

2.1.2 Miary kształtu rozkładu

Oprócz statystyk opisujących dynamikę procesu istotne informacje o charakterze trajektorii można uzyskać poprzez analizę kształtu rozkładu wartości procesu w danym czasie t. W niniejszym podrozdziale przedstawiono dwie klasy takich miar:

- parametry kształtu rozkładu – kurtozę i skośność,
- statystyki testowe czterech testów normalności: Andersona–Darlinga, Jarque–Bera, Kolmogorova–Smirnova oraz Shapiro–Wilka.

Wszystkie te wielkości obliczano dla kolejnych chwil czasu t, co pozwala ocenić, w jaki sposób zmienia się zgodność rozkładu procesu z rozkładem normalnym w zależności od modelu [26].

Kurtoza

Kurtoza mierzy koncentrację masy rozkładu wokół średniej oraz grubość jego ogonów i definiowana jest jako:

$$\mathrm{Kurt}(X) = \frac{\mathbb{E}[(X-\mu)^4]}{\sigma^4}, \tag{2.8}$$

gdzie μ i σ oznaczają odpowiednio średnią i odchylenie standardowe. Dla rozkładu normalnego wartość kurtozy wynosi 3.

Na Rys. 2.4 przedstawiono przebieg kurtozy rozkładu wartości procesu dla SBM oraz różnych wariantów SBMRE. Dla SBM krzywa stabilizuje się w pobliżu poziomu odpowiadającego rozkładowi normalnemu, co odzwierciedla jednorodną strukturę procesu o stałym wykładniku. W przypadku SBMRE wartości kurtozy są wyraźnie wyższe i wykazują tendencję rosnącą w czasie, szczególnie dla modelu z rozkładem dwupunktowym, jednak te z rozkładem jednostajnym i beta także generują wyraźne zwiększenie kurtozy. Oznacza to, że rozkłady SBMRE mają cięższe ogony, co jest bezpośrednim skutkiem zróżnicowania tempa wzrostu trajektorii wynikającego z losowości wykładnika $\mathcal{A}$.

Zachowanie widoczne na wykresie wskazuje, że analiza kurtozy dostarcza istotnej informacji o kształcie rozkładu i może skutecznie wspierać rozróżnianie modeli SBM i SBMRE.

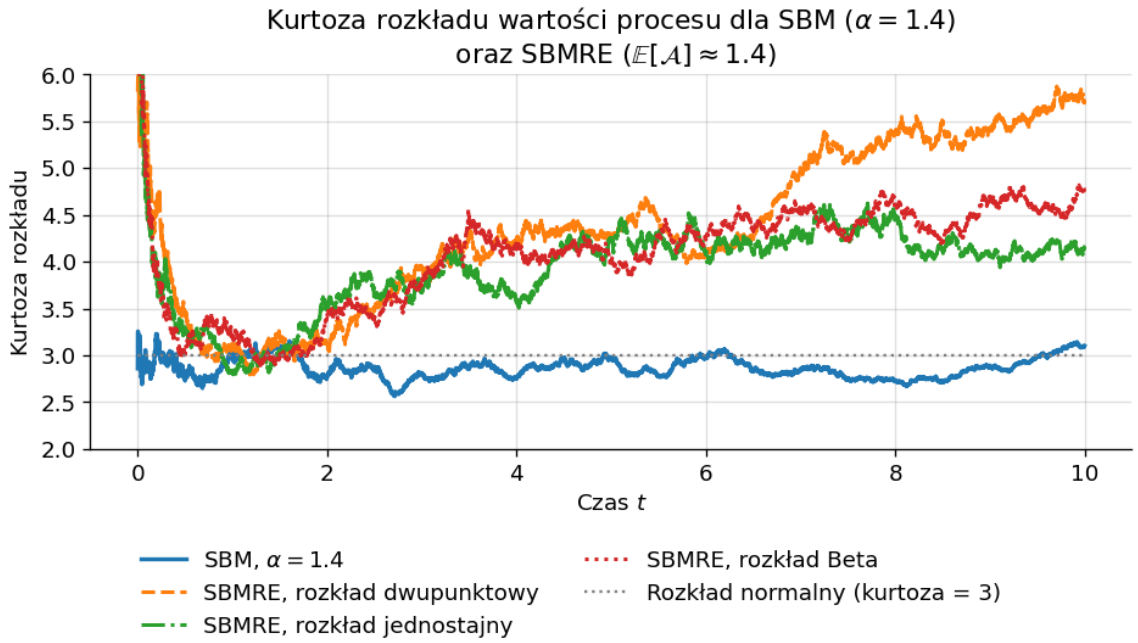

Rysunek 2.4: Kurtoza rozkładów SBM oraz SBMRE w czasie.

Skośność

Skośność mierzy asymetrię rozkładu i definiowana jest jako:

$$\mathrm{Skew}(X) = \frac{\mathbb{E}[(X-\mu)^3]}{\sigma^3}. \tag{2.9}$$

Dla rozkładu normalnego skośność wynosi 0.

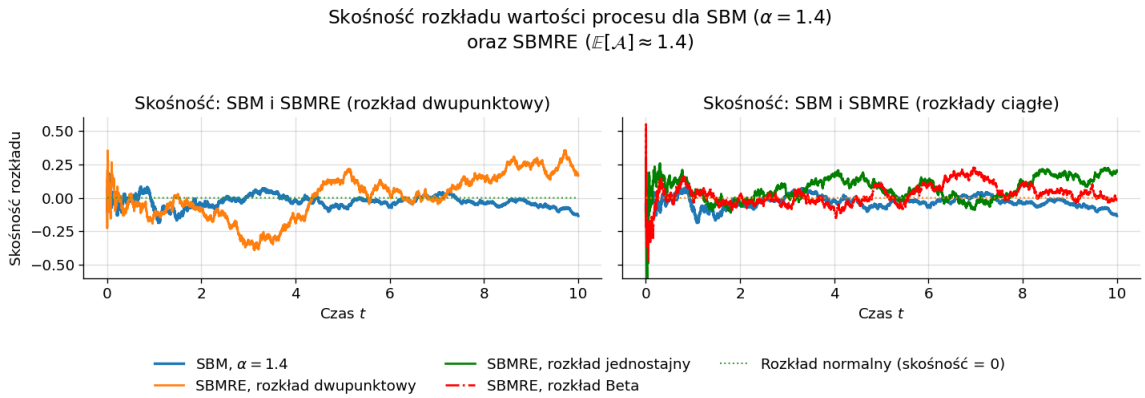

Rysunek 2.5: Skośność rozkładów SBM oraz SBMRE w czasie.

Na Rys. 2.5 przedstawiono przebieg skośności rozkładu wartości procesu $B(t)$ dla SBM oraz różnych wariantów SBMRE. W przypadku SBM krzywa pozostaje blisko zera, co wskazuje na symetrię rozkładu i jest zgodne z charakterystyką modelu o stałym wykładniku. Dla SBMRE obserwuje się wyraźnie większą zmienność skośności, a amplituda odchyleń jest szczególnie duża dla modelu z rozkładem dwupunktowym. Wynika to z faktu, że losowość wykładnika $\mathcal{A}$ powoduje nierównomierne przyspieszanie i spowalnianie trajektorii, co prowadzi do asymetrii rozkładu obserwowanych wartości procesu.

W porównaniu z kurtozą skośność ujawnia bardziej krótkoterminowe wahania kształtu rozkładu, choć jej zdolność rozróżniania poszczególnych wariantów SBMRE pozostaje umiarkowana. Widoczny na wykresie wzrost zmienności skośności dla SBMRE potwierdza, że miara ta reaguje na strukturalną niejednorodność procesu wynikającą z losowego wykładnika.

Test Andersona–Darlinga

Statystyka testowa Andersona–Darlinga jest zdefiniowana jako [1]:

$$A^2 = -n - \frac{1}{n}\sum_{i=1}^{n}(2i-1)\left[\ln F\Big(X_{(i)}\Big) + \ln\Big(1 - F\Big(X_{(n+1-i)}\Big)\Big)\right], \tag{2.10}$$

gdzie $X_{(i)}$ oznaczają uporządkowane niemalejąco obserwacje z próby, a F jest dystrybuantą rozkładu normalnego. Wyższe wartości statystyki wskazują na silniejsze odchylenie od normalności.

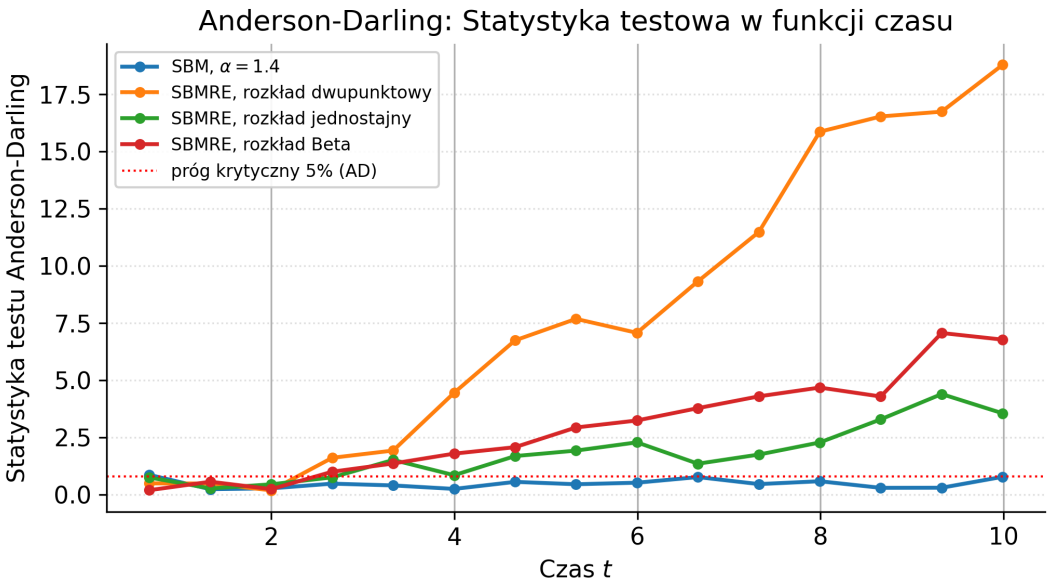

Rysunek 2.6: Statystyka testu Andersona–Darlinga dla SBM i SBMRE w czasie.

Na Rys. 2.6 przedstawiono wartości statystyki testu Andersona–Darlinga obliczanej dla kolejnych czasów t w modelach SBM i SBMRE. W przypadku SBM statystyka pozostaje niska i nie wykazuje wyraźnego trendu wzrostowego, co jest zgodne z normalnością rozkładu wartości procesu. Dla SBMRE obserwuje się systematyczny wzrost statystyki wraz z czasem, przy czym każdy yp rozkładu $\mathcal{A}$ daje inny charakter odchyleń w ogonach.Rozkład dwupunktowy wprowadza je najbardziej gwałtownie, natomiast beta i jednostajny generują odchylenia bardziej stopniowe. Wzrost ten odzwierciedla narastające odchylenie rozkładu $B(t)$ od normalności, wynikające ze zróżnicowania tempa wzrostu trajektorii w procesie z losowym wykładnikiem $\mathcal{A}$.

Test Andersona–Darlinga jest szczególnie czuły na zmiany w ogonach rozkładu, dlatego wyraźnie rozróżnia modele SBM i SBMRE, co potwierdzają widoczne na wykresie rosnące różnice pomiędzy przebiegami.

Test Jarque–Bera

Statystyka testowa Jarque–Bera ma postać [14]:

$$\mathrm{JB} = \frac{n}{6}\left(\mathrm{Skew}^2 + \frac{1}{4}\left(\mathrm{Kurt} - 3\right)^2\right) \tag{2.11}$$

i opiera się na jednoczesnym badaniu skośności i kurtozy.

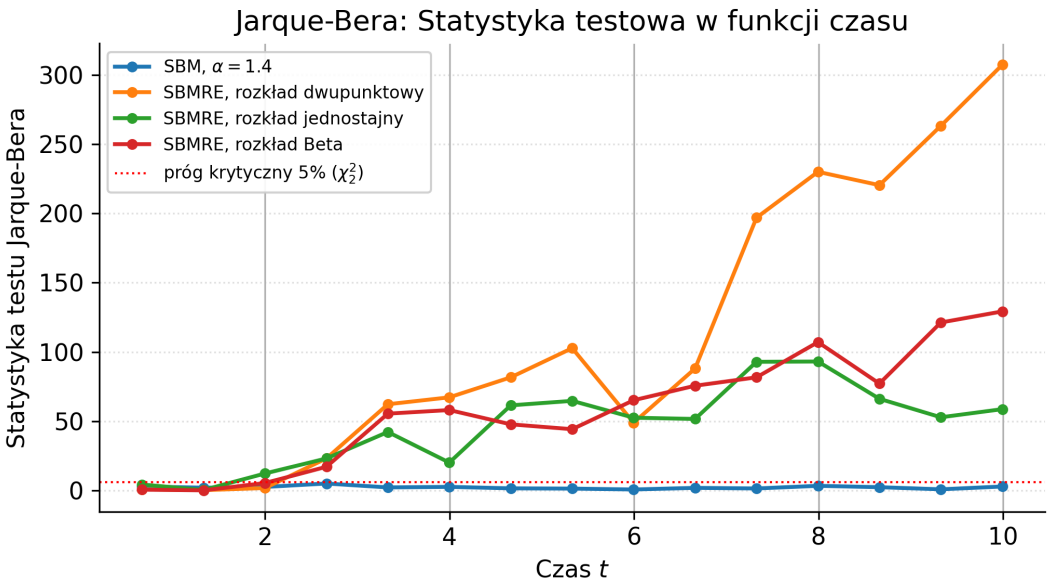

Rysunek 2.7: Statystyka testu Jarque–Bera dla SBM i SBMRE w czasie.

Na Rys. 2.7 przedstawiono wartości statystyki testu Jarque–Bera dla modeli SBM i SBMRE w funkcji czasu. W przypadku SBM statystyka pozostaje bliska zeru, co jest zgodne z symetrią i umiarkowaną kurtozą rozkładu wartości procesu. Dla wszystkich wariantów SBMRE obserwuje się wyraźny wzrost statystyki, jednak każdy z nich robi to w nieco innym tempie. Wzrost ten wynika z narastających odchyleń zarówno skośności, jak i kurtozy, które bezpośrednio wpływają na wartość testu Jarque–Bera.

Ponieważ statystyka JB łączy informacje o obu miarach kształtu rozkładu, jest szczególnie czuła na zmiany strukturalne wywołane losowością wykładnika $\mathcal{A}$. Widoczny na wykresie rozbieżny przebieg wartości statystyki dla SBMRE potwierdza jej przydatność w rozróżnianiu modeli SBM i SBMRE.

Test Kolmogorova–Smirnova

Test KS opiera się na supremum różnicy między dystrybuantą empiryczną a teoretyczną [19, 33]:

$$D = \sup_x \Big| F_n(x) - F(x) \Big|, \tag{2.12}$$

gdzie F_n oznacza dystrybuantę empiryczną wyznaczoną na podstawie próby $x_1, \ldots, x_n$, natomiast F jest dystrybuantą rozkładu normalnego. W analizowanym przypadku próba $x_1, \ldots, x_n$ składa się z wartości otrzymanych z realizacji procesu w ustalonym momencie czasu t, zebranych z wielu niezależnych trajektorii. Statystyka ta mierzy maksymalne odchylenie pomiędzy dystrybuantą empiryczną a teoretyczną, co pozwala ocenić stopień zgodności rozkładu obserwacji z rozkładem normalnym.

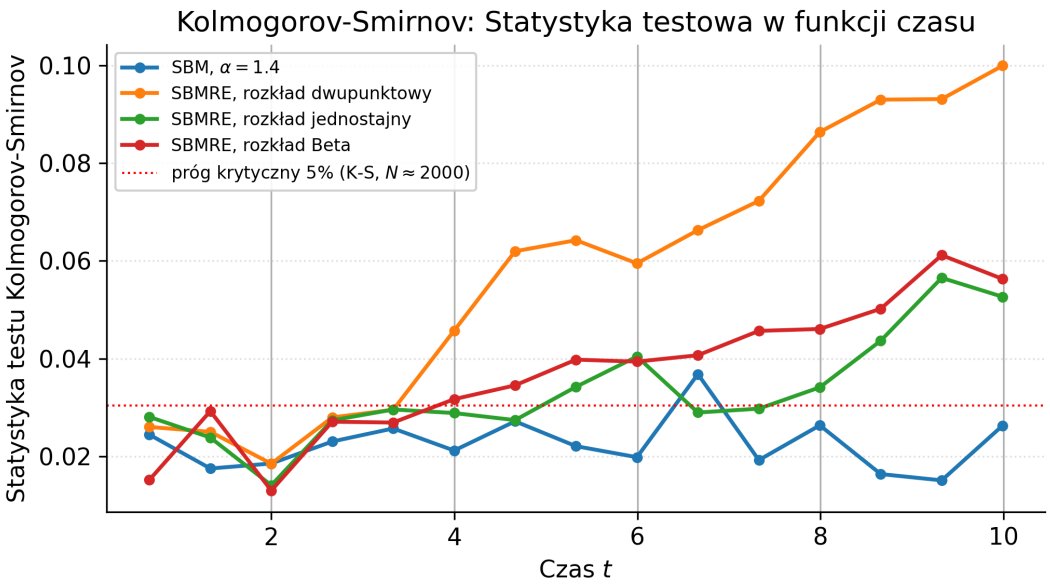

Rysunek 2.8: Statystyka testu Kolmogorova–Smirnova dla SBM i SBMRE w czasie.

Na Rys. 2.8 przedstawiono wartości statystyki testu Kolmogorova–Smirnova dla modeli SBM oraz SBMRE. Dla SBM przebieg statystyki jest stabilny i utrzymuje się na niskim poziomie, co wskazuje na dobrą zgodność rozkładu wartości procesu z rozkładem normalnym. W przypadku SBMRE obserwuje się systematyczny wzrost statystyki wraz z czasem, najwyraźniejszy dla modelu z rozkładem dwupunktowym wykładnika $\mathcal{A}$. Wzrost ten odzwierciedla narastające różnice między dystrybuantą wartości $B(t)$ a teoretyczną dystrybuantą normalną.

Test Kolmogorova–Smirnova jest mniej czuły na zmiany w ogonach niż test Andersona–Darlinga, jednak skutecznie wychwytuje ogólne odchylenia kształtu rozkładu. Widoczna na wykresie rozbieżność przebiegów dla SBM i SBMRE potwierdza, że również ta statystyka pozwala na rozróżnienie obu modeli.

Test Shapiro–Wilka

Statystyka testowa Shapiro–Wilka ma postać [32]:

$$W = \frac{\left(\sum_{i=1}^{n} a_i \, X_{(n+1-i)}\right)^2}{\sum_{i=1}^{n}\left(X_i - \bar{X}\right)^2}, \tag{2.13}$$

gdzie $X_1, \ldots, X_n$ oznaczają obserwacje tworzące próbę, $X_{(i)}$ są tymi obserwacjami uporządkowanymi niemalejąco, a współczynniki a_i zależą od wartości oczekiwanych oraz kowariancji statystyk porządkowych rozkładu normalnego.

W przeprowadzonych analizach obserwacje $X_1, \ldots, X_n$ odpowiadają wartościom procesu uzyskanym w ustalonym momencie czasu t z wielu niezależnych realizacji. Statystyka SW przyjmuje wartości bliskie 1 dla danych zgodnych z rozkładem normalnym, natomiast niższe wartości wskazują na narastające odchylenia od normalności.

Na Rys. 2.9 przedstawiono przebieg statystyki testu Shapiro–Wilka dla modeli SBM oraz SBMRE. W przypadku SBM statystyka pozostaje bardzo blisko wartości 1, co wskazuje na dobrą zgodność rozkładu wartości procesu $B(t)$ z rozkładem normalnym. Dla SBMRE

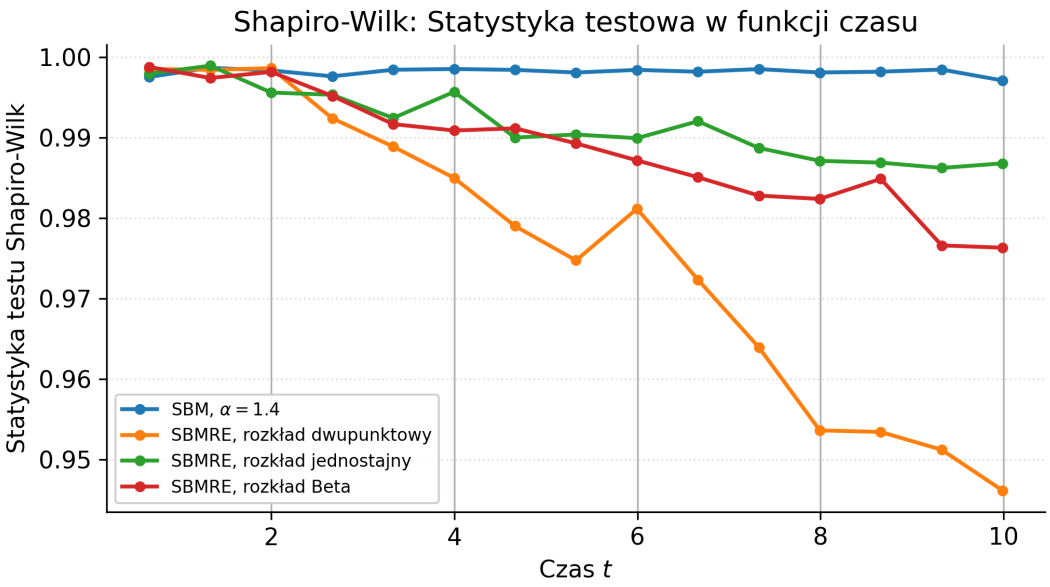

Rysunek 2.9: Statystyka testu Shapiro–Wilka dla SBM i SBMRE w czasie.

obserwuje się stopniowy spadek wartości statystyki wraz z czasem, najsilniej widoczny dla modelu z rozkładem dwupunktowym, zaś modele beta i jednostajny charakteryzują się bardziej wygładzonym, płynnym przebiegiem, co odzwierciedla mniej gwałtowne narastanie odchyleń w centralnej części rozkładu.

Test Shapiro–Wilka jest szczególnie czuły na zmiany kształtu rozkładu w jego centralnej części, co sprawia, że dobrze wychwytuje subtelne różnice między SBM i SBMRE. Widoczny na wykresie rozbieżny przebieg statystyki jednoznacznie potwierdza tę właściwość.

2.1.3 Podsumowanie wyboru cech

Na podstawie analizy przedstawionej w poprzednich podrozdziałach wybrano zestaw cech, które w sposób komplementarny opisują zarówno dynamikę procesu, jak i kształt rozkładu wartości. Cechy te odzwierciedlają różnice strukturalne pomiędzy SBM a SBMRE i stanowią wejście dla klasyfikatora opartego na sieci neuronowej.

Do reprezentacji własności czasowych wykorzystano:

- **MSD** – oddaje globalne skalowanie procesu, lecz nie rozróżnia jednoznacznie modeli, dlatego pełni funkcję pomocniczą;
- **TAMSD dla kilku wartości** τ – cecha silnie reagująca na zróżnicowanie tempa wzrostu trajektorii, szczególnie efektywna w odróżnianiu SBMRE od SBM;
- **DMA dla kilku wartości** τ – miara czuła na lokalne zmiany krzywizny trajektorii, ujawniająca niejednorodność charakterystyczną dla SBMRE.

Aby scharakteryzować zmienność rozkładu wartości procesu w czasie, uwzględniono:

- **kurtozę** – informującą o ciężkości ogonów,
- **skośność** – opisującą asymetrię rozkładu,

- **statystyki testów normalności** (AD, JB, KS, SW), które mierzą odchylenia od normalności wywołane losowością wykładnika $\mathcal{A}$.

Wybrane cechy obejmują zarówno informacje globalne (MSD), jak i lokalne (DMA), oraz odnoszą się do właściwości statystycznych całej trajektorii (TAMSD). Uzupełnienie ich o cechy opisujące kształt rozkładu pozwala uchwycić zarówno czasową, jak i probabilistyczną strukturę procesu. Tak skonstruowany zestaw cech jest wystarczająco bogaty, aby odróżnić model o stałym wykładniku od jego uogólnienia z wykładnikiem losowym. Jednocześnie cechy te są stabilne obliczeniowo i dobrze uogólniają się na różne rodzaje rozkładów $\mathcal{A}$, co czyni je odpowiednimi jako wejście do sieci neuronowej klasyfikującej trajektorie.

Dobór cech jest zgodny z podejściem opartym na analizie wieloskalowych własności trajektorii procesów anomalnej dyfuzji [26].

2.2 Architektura klasyfikatora i procedura uczenia

W drugiej części rozdziału przedstawiono model klasyfikacyjny oparty na sieci neuronowej, którego zadaniem jest rozróżnianie dwóch klas trajektorii. Omówiono konstrukcję zbioru danych, strukturę sieci oraz sposób jej trenowania.

2.2.1 Przygotowanie danych do klasyfikacji

W celu zbudowania uniwersalnego klasyfikatora trajektorii przygotowano zbiór danych obejmujący szeroki zakres parametrów procesów SBM i SBMRE. Zbiór ten został tak zaprojektowany, aby odzwierciedlał różnorodne dynamiki i własności statystyczne wynikające zarówno ze stałych wartości wykładnika α (SBM), jak i z jego losowości (SBMRE). Tak sformułowany zestaw stanowi wymagający materiał treningowy, pozwalający ocenić skuteczność klasyfikacji w ogólnych warunkach.

Trajektorie generowano numerycznie w przedziale $[0, 10]$ z krokiem $\Delta t = 10^{-3}$, zgodnie z algorytmami opisanymi w Rozdziale 1. Dla procesu SBM wykorzystano osiem wartości wykładnika α, reprezentujących zarówno zakres subdyfuzyjny, jak i superdyfuzyjny; dla każdej wartości wygenerowano 3300 trajektorii.

W przypadku SBMRE losowy wykładnik $\mathcal{A}$ losowano z rozkładów o ośmiu różnych wartościach oczekiwanych $\mathbb{E}[\mathcal{A}]$, dobranych tak, aby pokryć zakres od silnie subdyfuzyjnego do silnie superdyfuzyjnego. Dla każdej wartości średniej stosowano trzy rozkłady wykładnika: dwupunktowy, jednostajny oraz beta, co pozwalało uzyskać zróżnicowane formy losowości tempa wzrostu procesu. Każdy wariant generował 1100 trajektorii.

Dla każdej trajektorii obliczano zestaw cech, obejmujący globalne i lokalne miary dynamiki (MSD, TAMSD, DMA) oraz cechy opisujące kształt rozkładu wartości procesu (kurtozę, skośność i statystyki testów normalności: AD, KS, JB, SW). Wektory cech standaryzowano, co jest standardową praktyką w uczeniu modeli opartych na cechach [12]. Następnie dane podzielono na zbiory treningowy (60%), walidacyjny (20%) i testowy (20%) z użyciem podziału stratyfikowanego, aby zachować proporcje klas w każdej części zbioru [18].

Łącznie przygotowano $N = 52800$ trajektorii, z czego połowę stanowią realizacje SBM, a połowę procesy SBMRE generowane z losowym wykładnikiem $\mathcal{A}$. Tak rozbudowany zbiór pozwala ocenić skuteczność klasyfikacji w szczególnie zróżnicowanych i wymagających warunkach.

2.2.2 Architektura sieci neuronowej

Do klasyfikacji trajektorii zastosowano sieć neuronową typu MLP (*Multi–Layer Perceptron*), czyli klasyczną sieć warstw w pełni połączonych, powszechnie wykorzystywaną w zadaniach klasyfikacyjnych dla danych o niewielkim lub średnim wymiarze [11, 12]. Wejście modelu stanowi wektor cech opisujących dynamikę i własności statystyczne procesu, a architektura została dobrana tak, aby zapewnić wystarczającą elastyczność przy jednoczesnym zachowaniu niewielkiej liczby parametrów.

Model składa się z trzech warstw ukrytych o rozmiarach 64, 64 oraz 32 neuronów. We wszystkich warstwach ukrytych zastosowano funkcję aktywacji ReLU, która charakteryzuje się dobrą stabilnością numeryczną oraz sprzyja efektywnemu uczeniu głębszych modeli [11, 16]. Tak dobrana architektura umożliwia uchwycenie relacji pomiędzy cechami globalnymi i lokalnymi oraz ich nieliniowych zależności.

Warstwa wyjściowa zawiera dwa neurony odpowiadające rozważanym klasom (SBM i SBMRE), a zastosowanie funkcji softmax nadaje modelowi probabilistyczną interpretację wyjścia, co jest standardowym podejściem w klasyfikacji wieloklasowej [5].

W trakcie prac eksperymentalnych testowano również architektury o zwiększonej liczbie neuronów oraz dodatkowych warstwach, jednak nie prowadziły one do trwałej poprawy jakości klasyfikacji, natomiast zwiększały ryzyko przeuczenia. Wybrany model stanowi kompromis pomiędzy złożonością a stabilnością i okazał się najbardziej efektywny w analizowanym zadaniu.

2.2.3 Procedura uczenia

Proces uczenia sieci neuronowej przeprowadzono w sposób zgodny ze standardowymi metodami treningu modeli głębokich [11]. Jako funkcję kosztu zastosowano entropię krzyżową, która jest naturalnym wyborem w zadaniach klasyfikacji binarnej i wieloklasowej [5]. Optymalizację przeprowadzono za pomocą algorytmu Adam, łączącego cechy metod momentum i adaptacyjnego dostosowania kroku uczenia, co zapewnia stabilną i efektywną minimalizację funkcji kosztu, nawet przy zróżnicowanych skalach cech.

Uczenie realizowano w trybie mini-batch, z rozmiarem pakietu równym 128. W każdej epoce rejestrowano wartość funkcji kosztu oraz dokładność klasyfikacji na zbiorze treningowym i walidacyjnym, co umożliwiało monitorowanie przebiegu uczenia i kontrolę ewentualnego przeuczenia.

Aby ograniczyć ryzyko nadmiernego dopasowania modelu do danych treningowych, zastosowano mechanizm *early stopping*. Uczenie przerywano, gdy wartość funkcji kosztu na zbiorze walidacyjnym nie ulegała poprawie przez ustaloną liczbę epok, wybierając parametry modelu odpowiadające najlepszej jakości walidacyjnej [29].

Dodatkowo przeprowadzono walidację krzyżową w schemacie dziesięciokrotnego podziału stratyfikowanego (10-fold CV), co pozwala ocenić stabilność jakości klasyfikacji na różnych podzbiorach danych [12, 18]. Szczegółowe wyniki procesu uczenia, w tym przebiegi funkcji straty, dokładność klasyfikacji oraz rezultaty walidacji krzyżowej, przedstawiono w kolejnej sekcji.

2.2.4 Wyniki klasyfikacji dla modelu głównego

W niniejszej części przedstawiono rezultaty treningu klasyfikatora opartego na sieci neuronowej dla najbardziej ogólnego wariantu zbioru danych, obejmującego szeroki zakres parametrów procesów SBM oraz SBMRE. Analiza obejmuje przebieg uczenia modelu,

jego jakość na zbiorze testowym, wyniki walidacji krzyżowej, a także dodatkowe ilustracje, które pozwalają ocenić stabilność i skuteczność klasyfikatora.

Przebieg uczenia

Na Rys. 2.10 przedstawiono ewolucję funkcji straty oraz dokładności klasyfikacji dla zbiorów treningowego i walidacyjnego. W pierwszych epokach widoczny jest charakterystyczny dla modeli głębokich gwałtowny spadek wartości funkcji straty, co odzwierciedla szybkie dopasowanie parametrów sieci do podstawowej struktury danych. W tym samym okresie dokładność klasyfikacji rośnie z wartości początkowej około 0,53 do ponad 0,66 już po dziesięciu epokach, co wskazuje na efektywną adaptację modelu do zróżnicowanych przykładów z obu klas.

Po fazie początkowej tempo uczenia stopniowo maleje: funkcja straty na zbiorze treningowym nadal systematycznie opada, lecz krzywa walidacyjna stabilizuje się w okolicach 0,55. Równoległy przebieg obu krzywych sugeruje, że model nie ulega nadmiernemu dopasowaniu, co oznacza, że sieć poprawia dopasowanie do danych treningowych, jednocześnie zachowując podobną jakość predykcji na danych niewidzianych. Brak istotnej rozbieżności pomiędzy stratą treningową a walidacyjną świadczy o dobrej zdolności uogólniania klasyfikatora.

Wartości dokładności również wykazują stabilizację. Po około 70-80 epokach osiągana jest dokładność bliska 0.70, a dalszy przebieg uczenia prowadzi jedynie do niewielkich wahań wokół tej wartości. Najwyższą dokładność walidacyjną, równą około 0.702, odnotowano po 130–150 epokach. Mechanizm wczesnego zatrzymania (*early stopping*) przerwał trening po 171 epokach, gdy dalsze obniżanie straty walidacyjnej nie następowało, co pozwoliło wybrać parametry sieci odpowiadające najlepszej zdolności generalizacyjnej.

Zaobserwowany przebieg krzywych jest typowy dla modeli trenowanych na danych o częściowo nakładającej się strukturze klas. Stabilizacja dokładności poniżej 75% odzwierciedla naturalne ograniczenia separowalności procesów SBM i SBMRE, wynikające z podobieństwa niektórych trajektorii przy zbliżonych wartościach wykładnika.

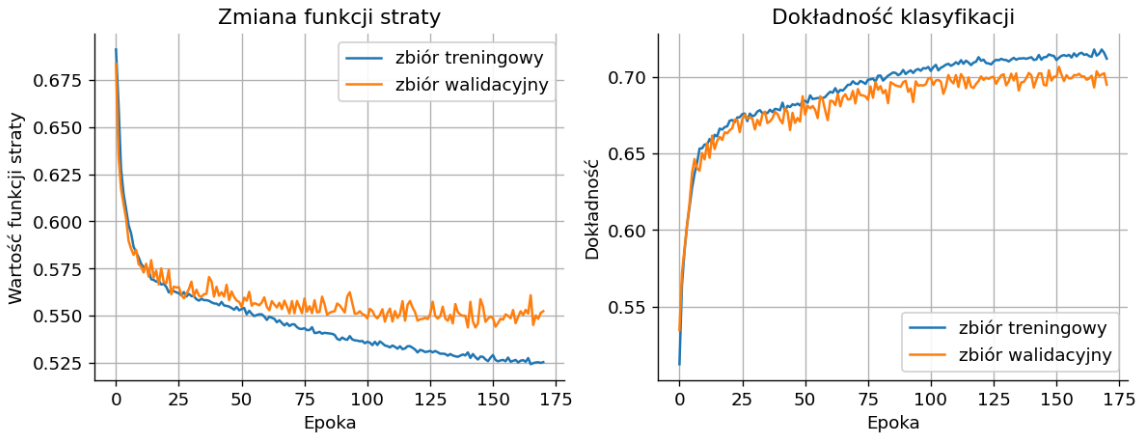

Rysunek 2.10: Przebieg uczenia klasyfikatora MLP: wartość funkcji straty (po lewej) oraz dokładność klasyfikacji (po prawej) dla zbiorów treningowego i walidacyjnego.

Wyniki na zbiorze testowym

Jakość działania wytrenowanego klasyfikatora oceniono na niezależnym zbiorze testowym obejmującym 10560 trajektorii, po 5280 reprezentujących procesy SBM oraz SBMRE. Uzyskano dokładność równą 0.702, a wartość funkcji straty wyniosła 0.5473. Wartości te są zbliżone do wyników walidacyjnych, co potwierdza stabilne uogólnianie modelu oraz brak nadmiernego dopasowania do danych treningowych.

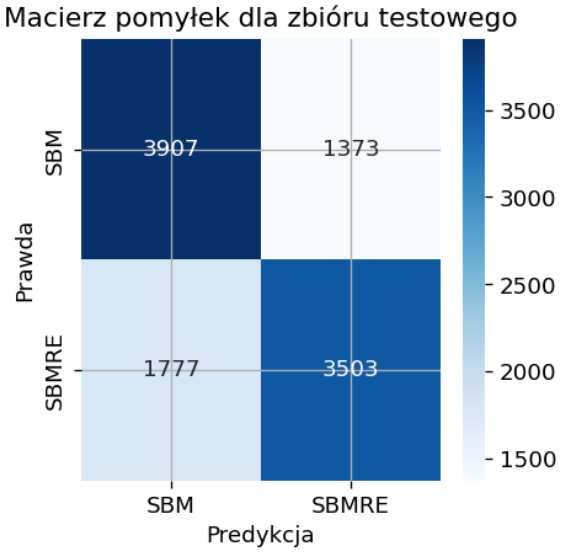

Rysunek 2.11: Macierz pomyłek dla zbioru testowego.

Macierz pomyłek przedstawiona na Rys. 2.11 pozwala przeanalizować sposób, w jaki model popełnia błędy klasyfikacji. Klasyfikator poprawnie rozpoznaje 3907 z 5280 trajektorii SBM oraz 3503 z 5280 trajektorii SBMRE, co odpowiada odpowiednio współczynnikom recall równym 0.74 i 0.66. Wyraźnie widać, że model częściej myli trajektorie SBMRE z SBM (1777 przypadków), niż odwrotnie. Wskazuje to, że klasyfikator jest bardziej ostrożny w przypisywaniu etykiety SBMRE, preferując klasyfikację do SBM w sytuacjach niejednoznacznych. Takie zachowanie jest zgodne z naturą danych: część trajektorii SBMRE generowanych dla wartości wykładnika $\mathcal{A}$ bliskich parametrom SBM przyjmuje przebiegi praktycznie nierozróżnialne od ruchu ze stałym wykładnikiem.

Krzywa ROC i wartość AUC

Dodatkową ocenę jakości klasyfikatora uzyskano na podstawie krzywej ROC, przedstawionej na Rys. 2.12. Krzywa ta ilustruje zależność pomiędzy czułością klasyfikacji (True Positive Rate) a odsetkiem fałszywych alarmów (False Positive Rate) dla różnych wartości progu decyzyjnego stosowanego na wyjściu sieci neuronowej. W przeciwieństwie do pojedynczej wartości dokładności, krzywa ROC opisuje działanie klasyfikatora w pełnym zakresie możliwych progów, a więc dostarcza pełniejszej charakterystyki jego właściwości decyzyjnych [10].

Wynikowy przebieg znacząco przewyższa linię przekątnej odpowiadającą klasyfikatorowi losowemu, co świadczy o rzeczywistej zdolności modelu do rozróżniania procesów SBM i SBMRE. Wartość AUC równa 0.782 oznacza, że w około 78% przypadkach model przypisuje trajektorii SBMRE wyższe prawdopodobieństwo przynależności do klasy SBMRE niż trajektorii SBM.

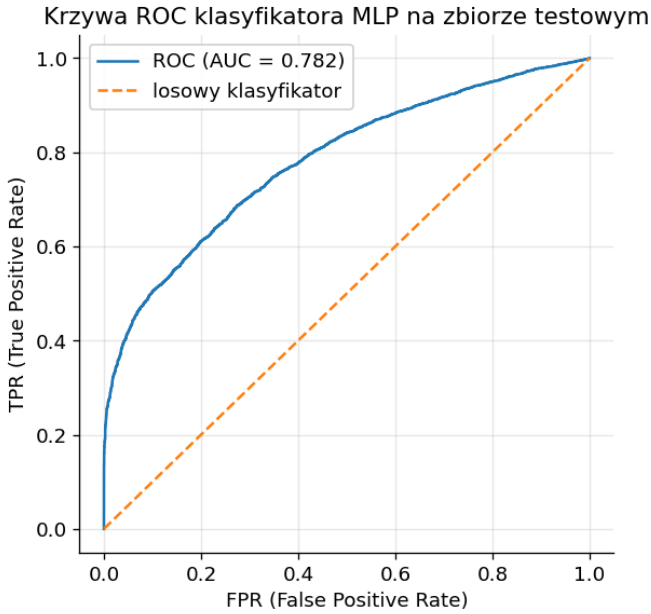

Rysunek 2.12: Krzywa ROC klasyfikatora MLP na zbiorze testowym.

Otrzymany poziom AUC potwierdza skuteczność modelu, a jednocześnie wskazuje na istniejące nakładanie się klas, które ogranicza maksymalną możliwą separowalność zbioru danych. Wartość AUC jest przy tym wyższa niż dokładność klasyfikacji, co sugeruje, że model dysponuje użyteczną informacją o strukturze danych również poza standardowym progiem decyzyjnym 0.5.

Krzywa uczenia

Na Rys. 2.13 przedstawiono krzywą uczenia klasyfikatora, ilustrującą wpływ liczby dostępnych danych treningowych na jakość predykcji. Model trenowano na podzbiorach obejmujących od 10% do 100% danych, a następnie oceniano dokładność na wspólnym zbiorze testowym.

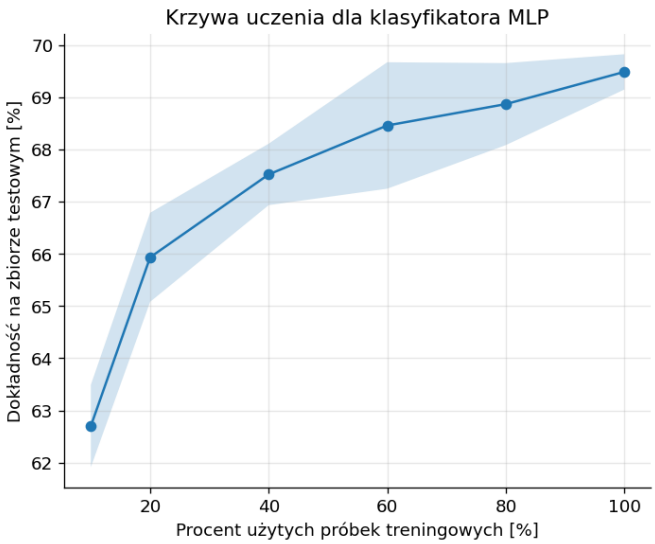

Rysunek 2.13: Krzywa uczenia klasyfikatora MLP.

Dokładność rośnie systematycznie wraz ze zwiększaniem liczby trajektorii w zbiorze treningowym od około 62% przy 10% danych do niemal 69% przy pełnym zbiorze. Największy przyrost występuje pomiędzy 10% a 40%, natomiast powyżej 60% krzywa zaczyna się wypłaszczać, co wskazuje, że dodatkowe dane nadal poprawiają wyniki, lecz w coraz wolniejszym tempie.

Stabilny wzrost dokładności oraz brak oznak przeuczenia wskazują, że model efektywnie wykorzystuje dostępne trajektorie, a dalsza poprawa wyników jest ograniczona głównie charakterem samych danych.

Walidacja krzyżowa

Aby ocenić stabilność działania klasyfikatora oraz jego podatność na zmiany podziału danych, przeprowadzono dziesięciokrotną walidację krzyżową (10-fold CV), polegającą na wielokrotnym losowym podziale danych na zbiory treningowe i walidacyjne. W każdym powtórzeniu model był trenowany na nowej części danych, a jego jakość oceniano na odpowiadającym jej zbiorze walidacyjnym. Uzyskane wyniki zestawiono w Tab. 2.1.

Tabela 2.1: Wyniki 10-krotnej walidacji krzyżowej (dokładność w poszczególnych foldach).

Fold	**Accuracy**
1	0.7074
2	0.7068
3	0.7133
4	0.7100
5	0.7116
6	0.7038
7	0.7218
8	0.7208
9	0.7002
10	0.7121
Średnia	**0.711**
Odchylenie standardowe	**0.0065**

Wyniki walidacji krzyżowej są bardzo spójne: dokładność w poszczególnych foldach mieści się w przedziale $0.70 - 0.72$, a odchylenie standardowe wynosi jedynie około 0.0065. Tak niewielka zmienność potwierdza, że model jest stabilny względem podziału danych i nie zależy od przypadkowego wyboru trajektorii w zbiorze treningowym. Otrzymana średnia dokładność na poziomie około 71% jest zgodna z wartością uzyskaną dla standardowego podziału train/val/test, co dodatkowo potwierdza wiarygodność uzyskanego wyniku.

Podsumowanie

Przeprowadzona analiza potwierdza, że zaproponowany klasyfikator MLP jest w stanie rozróżniać trajektorie procesów SBM i SBMRE z dobrą, stabilną skutecznością. Przebieg uczenia nie wykazuje oznak przeuczenia, a jakość predykcji na zbiorze walidacyjnym i testowym utrzymuje się na poziomie około 70%. Macierz pomyłek oraz krzywa ROC pokazują, że model nie tylko poprawnie identyfikuje większość trajektorii obu typów, lecz także generuje dobrze skalibrowane prawdopodobieństwa, czego odzwierciedleniem jest wartość AUC równa 0.78.

Walidacja krzyżowa potwierdza wysoką stabilność modelu względem doboru danych treningowych, a krzywa uczenia wskazuje, że jakość klasyfikacji rośnie wraz z liczbą dostępnych trajektorii, po czym ulega stabilizacji na poziomie około 70% dokładności. Ograniczenia jakości wynikają przede wszystkim z częściowego podobieństwa trajektorii SBM i SBMRE, co potwierdzają zarówno analiza cech, jak i charakter samych procesów.

Łącznie uzyskane wyniki wskazują, że model MLP stanowi wiarygodne i efektywne narzędzie do automatycznego rozróżniania trajektorii SBM i SBMRE, zachowując dobrą generalizację przy szerokiej zmienności parametrów procesów.

2.2.5 Modele porównawcze

Oprócz modelu ogólnego rozważono również dwa uproszczone warianty zadania klasyfikacyjnego. Celem tej analizy było sprawdzenie, jak zmienia się trudność problemu po zawężeniu zakresu parametrów procesów oraz na ile uzyskane wcześniej wyniki są efektem złożoności samego zbioru danych.

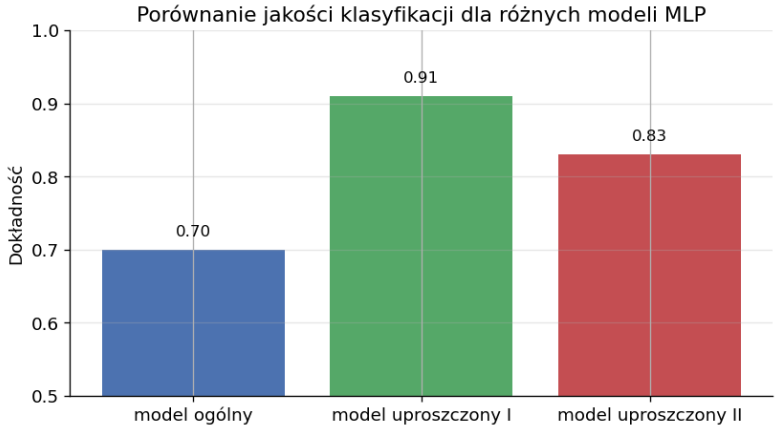

Rysunek 2.14: Porównanie dokładności klasyfikacji dla modelu ogólnego oraz dwóch modeli uproszczonych.

Pierwszy model uproszczony (oznaczony na Rys. 2.14 jako *model uproszczony I*) obejmował wyłącznie trajektorie procesu SBM z jednym ustalonym wykładnikiem $\alpha = 1.4$ oraz odpowiadające im trajektorie SBMRE o tej samej wartości oczekiwanej $\mathbb{E}[\mathcal{A}] = 1.4$. W takim ustawieniu klasy różnią się głównie obecnością losowości wykładnika, natomiast globalne skalowanie procesu jest stałe. Zadanie okazało się znacznie prostsze niż w przypadku modelu ogólnego, a klasyfikator osiągnął dokładność istotnie powyżej 90%.

Drugi model uproszczony (oznaczony na Rys. 2.14 jako *model uproszczony II*) obejmował dwa poziomy dynamiki: przypadek subdyfuzyjny, odpowiadający procesowi SBM z wykładnikiem dyfuzji $\alpha = 0.6$ oraz procesowi SBMRE o wartości oczekiwanej wykładnika $\mathbb{E}[A] = 0.6$, a także przypadek superdyfuzyjny, opisany przez proces SBM z wykładnikiem $\alpha = 1.4$ oraz odpowiadający mu proces SBMRE o wartości oczekiwanej $\mathbb{E}[A] = 1.4$. Zakres parametrów był więc szerszy niż w pierwszym wariancie, ale nadal znacznie węższy niż w modelu ogólnym. Uzyskana dokładność pozostawała wyraźnie wyższa niż w pełnym zadaniu (istotnie powyżej 80%), co pokazuje, że zawężenie przestrzeni parametrów ułatwia rozróżnianie klas.

Porównanie jakości klasyfikacji dla trzech omawianych modeli przedstawiono na Rys. 2.14. Widać wyraźnie, że model ogólny osiąga najniższą dokładność, co wynika

z największej różnorodności rozważanych procesów oraz częściowego nakładania się ich własności statystycznych. Jednocześnie wyniki modeli uproszczonych potwierdzają, że zaproponowane cechy oraz architektura sieci są w stanie bardzo dobrze rozróżniać SBM i SBMRE w prostszych scenariuszach, a spadek dokładności w modelu ogólnym jest konsekwencją zwiększonej złożoności zadania, a nie słabości samego klasyfikatora.

2.2.6 Podsumowanie

Zastosowany klasyfikator MLP okazał się skutecznym narzędziem do rozróżniania trajektorii procesów SBM i SBMRE, wykorzystując wybrane cechy dynamiki oraz statystyki opisujące kształt rozkładu. Model trenowany na pełnym, zróżnicowanym zbiorze osiągnął stabilną jakość predykcji na poziomie około 70%, co potwierdziły zarówno wyniki na zbiorze testowym, jak i walidacja krzyżowa. Krzywa ROC oraz wartość AUC równa 0.78 wskazują, że klasyfikator poprawnie porządkuje trajektorie według prawdopodobieństwa przynależności do klasy, mimo częściowego podobieństwa obu procesów.

Analiza modeli uproszczonych pokazała, że zawężenie zakresu parametrów istotnie ułatwia klasyfikację, prowadząc do znacznie wyższej dokładności. Kontrast ten podkreśla, że głównym wyzwaniem w modelu ogólnym jest szeroka różnorodność dynamiki procesów, a nie ograniczenia samej architektury. Wyniki potwierdzają, że zaproponowane cechy oraz zastosowana sieć MLP są dobrze przystosowane do zadania i mogą stanowić solidną podstawę do dalszych analiz porównawczych.

Rozdział 3

Analiza danych symulowanych

W niniejszym rozdziale przedstawiono analizę danych symulowanych, której celem jest pogłębione zrozumienie własności procesów SBM oraz SBMRE oraz ocena zachowania wybranych cech w zależności od parametrów symulacji. Analiza ta stanowi powszechnie stosowane narzędzie w badaniu własności procesów anomalnej dyfuzji, pozwalając na weryfikację przewidywań teoretycznych oraz ocenę zachowania estymatorów w warunkach skończonej próby [15, 28], a jednocześnie uzupełnia rozważania teoretyczne oraz wyniki klasyfikacji przedstawione w poprzednim rozdziale.

W szczególności zbadano wpływ długości trajektorii, wartości wykładnika dyfuzji oraz rodzaju jego losowości na charakter realizacji procesu. Dodatkowo przeanalizowano wpływ kroku czasowego na stabilność obliczanych statystyk. Uzyskane wyniki pozwalają lepiej zinterpretować skuteczność zaproponowanych metod rozróżniania SBM i SBMRE oraz wskazują ograniczenia wynikające z charakteru danych.

O ile nie zaznaczono inaczej, wszystkie analizy przedstawione w niniejszym rozdziale wykonano dla domyślnych parametrów symulacji, zgodnych z ustawieniami przyjętymi w poprzednich częściach pracy. Trajektorie generowano na przedziale czasowym $[0, 10]$ z krokiem $\Delta t = 10^{-3}$, a liczba realizacji w każdej analizie wynosiła 10 000.

Dla procesu SBM stosowano stały wykładnik dyfuzji $\alpha = 1.4$. W przypadku SBMRE losowy wykładnik generowano z trzech typów rozkładów: dwupunktowego, jednostajnego oraz beta. Rozkład dwupunktowy przyjmował dwie wartości $\alpha = 0.8$ oraz $\alpha = 2.0$ z prawdopodobieństwem $p = 0.5$. Rozkład jednostajny oraz rozkład beta były przeskalowane do przedziału $[0.8, 2.0]$, przy czym w przypadku rozkładu beta stosowano ustalone parametry kształtu $a = b = 0.5$. We wszystkich przypadkach wartość oczekiwana losowego wykładnika była równa 1.4.

3.1 Wpływ długości trajektorii

Długość obserwowanej trajektorii stanowi jeden z kluczowych czynników wpływających na stabilność estymowanych statystyk czasowych oraz możliwość rozróżniania procesów o stałych i losowych parametrach dyfuzji. W niniejszej sekcji przeanalizowano wpływ długości trajektorii $T \in \{1, 5, 10\}$ na własności procesów SBM oraz SBMRE, przy ustalonym opóźnieniu $\tau = 0.05$. Szczególną uwagę poświęcono zachowaniu TAMSD oraz rozkładu kurtozy przyrostów, które stanowią istotne charakterystyki dynamiki pojedynczych realizacji.

TAMSD jest jedną z podstawowych statystyk wykorzystywanych do opisu własności dyfuzyjnych trajektorii. Jego wartość oraz zmienność pomiędzy realizacjami dostarczają informacji na temat ergodyczności procesu oraz jednorodności jego parametrów. W przy-

padku procesów o stałych parametrach dyfuzji oczekuje się, że wraz z wydłużeniem trajektorii wartości TAMSD będą ulegały stabilizacji, natomiast w procesach z losowymi parametrami może dochodzić do utrzymywania się lub nawet wzrostu zmienności tej statystyki.

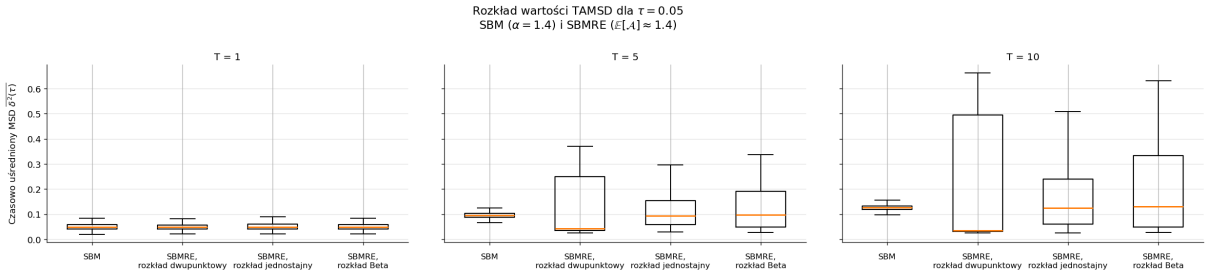

Rysunek 3.1: Rozkłady wartości TAMSD dla $\tau = 0.05$ oraz różnych długości trajektorii T dla SBM i SBMRE

Na Rys. 3.1 przedstawiono rozkłady wartości TAMSD dla różnych długości trajektorii procesów SBM oraz SBMRE.

Dla procesu SBM obserwuje się wyraźną tendencję do zmniejszania rozrzutu wartości TAMSD wraz ze wzrostem długości trajektorii. Rozkłady dla krótkich trajektorii ($T = 1$) charakteryzują się relatywnie dużą zmiennością pomiędzy realizacjami, natomiast dla dłuższych ($T = 10$) są znacznie bardziej skoncentrowane wokół wartości mediany. Zjawisko to potwierdza analiza współczynnika zmienności, który maleje z 0.2702 dla $T = 1$ do 0.0862 dla $T = 10$, co odpowiada spadkowi o około 68%. Takie zachowanie jest zgodne z ergodycznym charakterem procesu SBM i wynika z faktu, że wraz z wydłużeniem obserwacji następuje skuteczne uśrednianie fluktuacji losowych [15, 28].

Odmienne zachowanie obserwuje się w przypadku procesów SBMRE [26, 37]. Dla wszystkich rozważanych rozkładów losowego wykładnika $\mathcal{A}$ zmienność wartości TAMSD nie maleje wraz z długością trajektorii, lecz przeciwnie - wyraźnie wzrasta. W przypadku rozkładu dwupunktowego współczynnik zmienności zwiększa się z 0.2571 dla $T = 1$ do 0.9404 dla $T = 10$, co oznacza wzrost o ponad 260%. Podobne tendencje obserwuje się dla rozkładu jednostajnego oraz beta. Oznacza to, że wydłużanie trajektorii nie prowadzi do ujednolicenia zachowania realizacji, lecz uwidacznia różnice wynikające z losowości parametru dyfuzji, prowadząc do rosnącej heterogeniczności estymatora TAMSD.

Uzupełnieniem analizy TAMSD jest badanie rozkładu kurtozy przyrostów, które pozwala ocenić kształt rozkładu fluktuacji oraz obecność wartości ekstremalnych. Kurtoza stanowi miarę wrażliwą na odstępstwa od rozkładu normalnego, a jej analiza dostarcza dodatkowych informacji na temat struktury statystycznej przyrostów procesu.

Na Rys. 3.2 przedstawiono rozkłady kurtozy przyrostów dla różnych długości trajektorii. Dla procesu SBM mediany kurtozy dla wszystkich analizowanych długości trajektorii pozostają bliskie wartości 3, charakterystycznej dla rozkładu normalnego. Jednocześnie, wraz ze wzrostem długości trajektorii, obserwuje się systematyczne zmniejszanie rozstępu międzykwartylowego, który maleje z 0.674 dla $T = 1$ do 0.260 dla $T = 10$. Świadczy to o rosnącej jednorodności rozkładów przyrostów oraz stabilizacji ich własności statystycznych.

W przypadku procesów SBMRE medianowe wartości kurtozy są wyższe niż w przypadku SBM, szczególnie dla rozkładu dwupunktowego, gdzie dla $T = 10$ osiągają poziom około 3.6. Co istotne, rozstęp międzykwartylowy pozostaje relatywnie duży i nie wykazuje jednoznacznej tendencji malejącej wraz z długością trajektorii. Oznacza to, że losowość

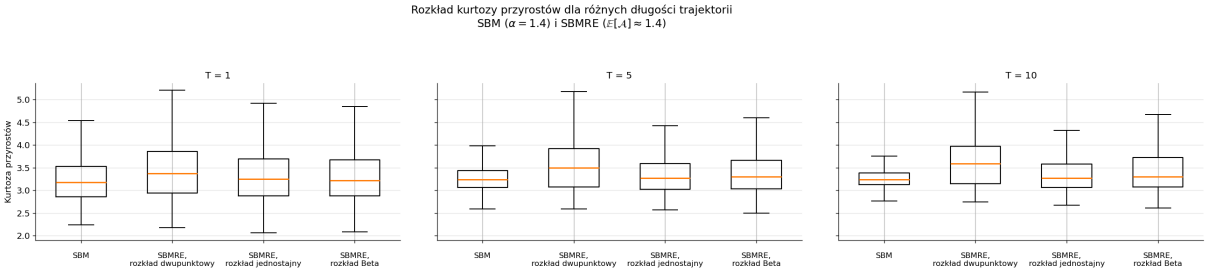

Rysunek 3.2: Rozkłady kurtozy przyrostów dla różnych długości trajektorii T dla SBM oraz SBMRE.

wykładnika dyfuzji prowadzi do trwałej zmienności rozkładu przyrostów, nawet dla długich realizacji, oraz do częstszego występowania wartości ekstremalnych.

Podsumowując, przeprowadzona analiza wskazuje, że długość trajektorii ma zasadniczo odmienny wpływ na własności statystyczne procesów SBM i SBMRE. W przypadku SBM wydłużanie trajektorii prowadzi do stabilizacji zarówno wartości TAMSD, jak i rozkładu przyrostów, co wynika z faktu, że wraz z wydłużeniem obserwacji własności statystyczne pojedynczych trajektorii ulegają stabilizacji i stają się zbliżone pomiędzy realizacjami. Natomiast dla procesów SBMRE zwiększanie długości trajektorii uwidacznia trajektoryjną heterogeniczność wynikającą z losowości wykładnika dyfuzji, objawiającą się rosnącą zmiennością TAMSD oraz utrzymującą się podwyższoną kurtozą przyrostów. W konsekwencji długość trajektorii stanowi istotny czynnik wzmacniający różnice pomiędzy procesami SBM i SBMRE, co ma kluczowe znaczenie w kontekście ich dalszej analizy oraz rozróżniania.

3.2 Wpływ wartości wykładnika dyfuzji

Wykładnik dyfuzji α stanowi kluczowy parametr procesu SBM, determinujący charakter jego dynamiki. W zależności od jego wartości proces może wykazywać zachowanie subdyfuzyjne ($\alpha < 1$), normalną dyfuzję ($\alpha = 1$) lub superdyfuzję ($\alpha > 1$). W niniejszej sekcji przeanalizowano wpływ wartości wykładnika dyfuzji na własności procesu SBM, koncentrując się na zachowaniu funkcji MSD oraz rozkładzie wartości TAMSD.

Analizę przeprowadzono dla pięciu wartości wykładnika dyfuzji: $\alpha \in \{0.5, 0.75, 1.0, 1.25, 1.5\}$, obejmujących zarówno zakres subdyfuzyjny, jak i superdyfuzyjny. Pozwala to na bezpośrednie porównanie dynamiki procesu w różnych reżimach dyfuzji.

Podstawową charakterystyką opisującą dynamikę procesu dyfuzyjnego jest funkcja MSD, której teoretyczna postać dla procesu SBM spełnia zależność $\mathrm{MSD}(t) \sim t^{\alpha}$. Oznacza to, że wartość wykładnika α bezpośrednio determinuje tempo wzrostu MSD w czasie.

Na Rys. 3.3 przedstawiono przebiegi funkcji MSD w skali logarytmicznej dla różnych wartości wykładnika dyfuzji. Zastosowanie skali log–log umożliwia bezpośrednią ocenę nachylenia krzywych, które odpowiada wartości parametru α. Dla mniejszych wartości wykładnika ($\alpha = 0.5, 0.75$) obserwuje się wolniejszy wzrost MSD, charakterystyczny dla procesów subdyfuzyjnych. W przypadku $\alpha = 1.0$ zależność ma charakter liniowy w skali logarytmicznej, co odpowiada klasycznemu ruchowi Browna. Natomiast dla $\alpha > 1$ krzywe MSD wykazują coraz większe nachylenie, wskazując na przyspieszoną dynamikę procesu w reżimie superdyfuzji.

Uzupełnieniem analizy MSD jest badanie rozkładu czasowo uśrednionego MSD, który

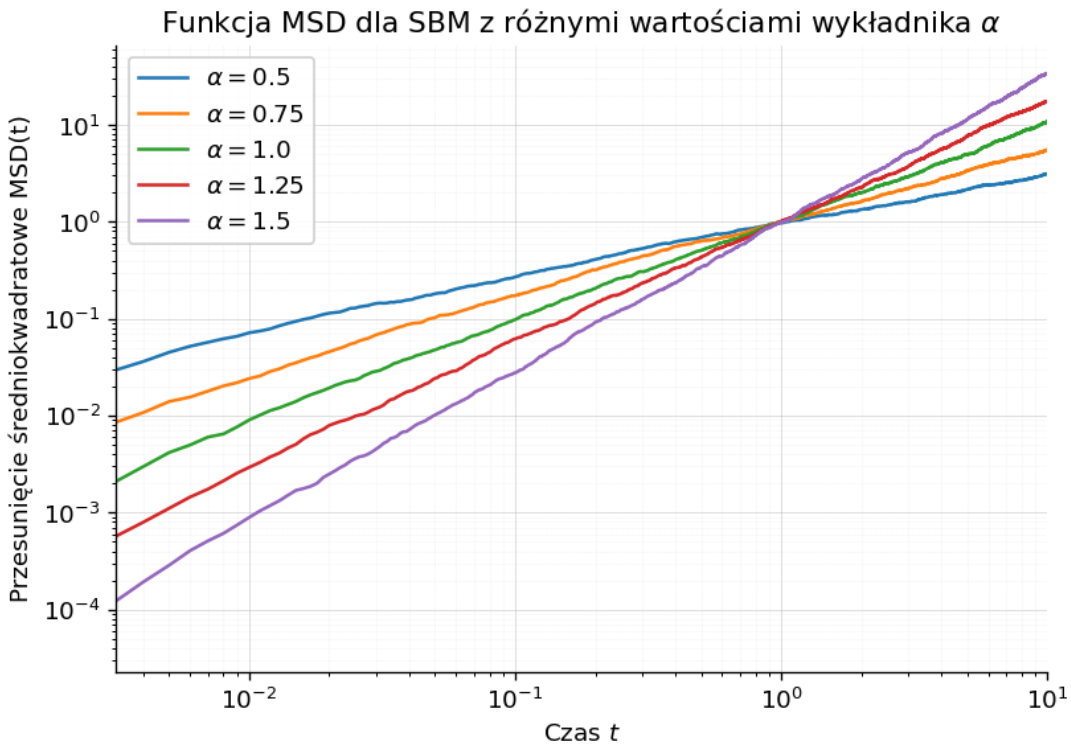

Rysunek 3.3: Funkcja MSD dla SBM z różnymi wartościami wykładnika dyfuzji α w skali log–log.

opisuje zachowanie pojedynczych trajektorii. Na Rys. 3.4 przedstawiono rozkłady wartości TAMSD dla ustalonego opóźnienia $\tau = 0.05$ oraz różnych wartości wykładnika dyfuzji.

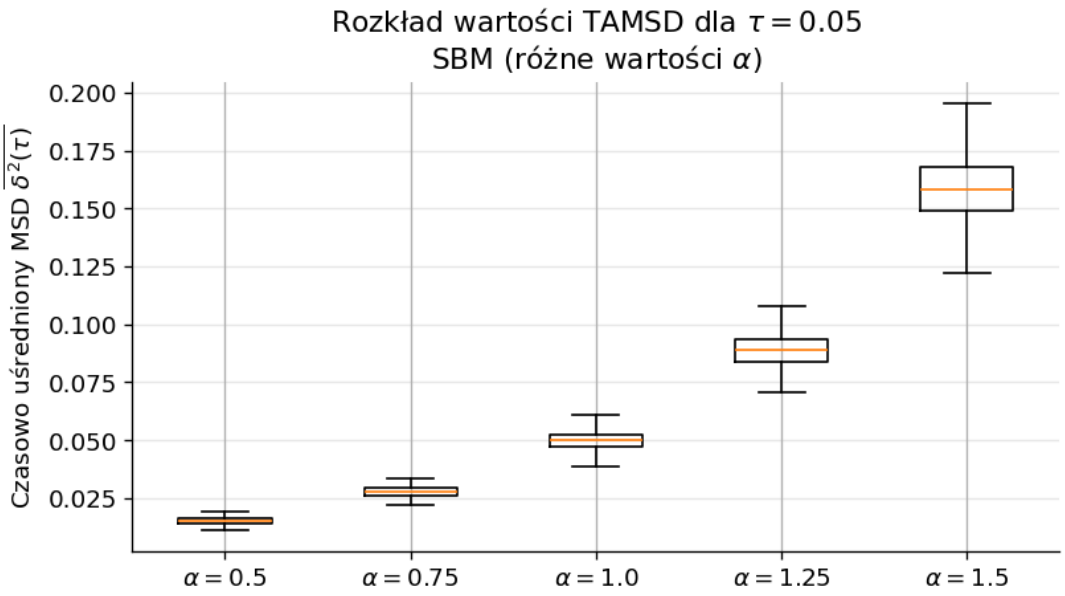

Rysunek 3.4: Rozkłady wartości TAMSD dla $\tau = 0.05$ dla procesu SBM przy różnych wartościach wykładnika dyfuzji α.

Wraz ze wzrostem wartości α obserwuje się systematyczny wzrost poziomu wartości TAMSD. Dla procesów subdyfuzyjnych ($\alpha = 0.5$ oraz $\alpha = 0.75$) rozkłady TAMSD

są skoncentrowane na relatywnie niskich wartościach, co odzwierciedla wolniejsze tempo rozprzestrzeniania się trajektorii. Dla $\alpha = 1.0$ wartości TAMSD przyjmują poziom pośredni. Natomiast dla wartości superdyfuzyjnych ($\alpha = 1.25$ oraz $\alpha = 1.5$) obserwuje się istotny wzrost mediany oraz całego zakresu rozkładu TAMSD.

Zaobserwowane różnice wskazują, że wykładnik dyfuzji α ma bezpośredni i jednoznaczny wpływ zarówno na tempo wzrostu średniego kwadratu przesunięcia, jak i na poziom wartości TAMSD dla pojedynczych trajektorii. Zwiększanie wartości α prowadzi do coraz szybszego wzrostu odległości pokonywanych przez cząstkę oraz do wzrostu zmienności obserwowanych przesunięć.

Podsumowując, analiza wpływu wartości wykładnika dyfuzji potwierdza jego kluczową rolę w kształtowaniu dynamiki procesu SBM. Zarówno funkcja MSD, jak i rozkłady TAMSD jednoznacznie odzwierciedlają przejście od subdyfuzji do superdyfuzji wraz ze wzrostem parametru α. Wyniki te pokazują, w jaki sposób zmiana wykładnika dyfuzji wpływa na tempo rozprzestrzeniania się trajektorii oraz na poziom obserwowanych fluktuacji.

3.3 Wpływ rodzaju losowości wykładnika w SBMRE

W poprzednich sekcjach wykazano, że sama obecność losowości wykładnika dyfuzji prowadzi do istotnych różnic pomiędzy procesami SBM i SBMRE. W niniejszej sekcji analizę pogłębiono, koncentrując się na wpływie rodzaju losowości wykładnika dyfuzji na własności procesu SBMRE. Celem jest sprawdzenie, czy przy tej samej wartości oczekiwanej wykładnika dyfuzji $\mathbb{E}[A] \approx 1.4$ charakter rozkładu losowego parametru $\mathcal{A}$ prowadzi do istotnych różnic w zachowaniu wybranych cech statystycznych.

Analizę przeprowadzono dla trzech typów rozkładów losowego wykładnika dyfuzji: dwupunktowego, jednostajnego oraz beta. We wszystkich przypadkach zachowano tę samą wartość oczekiwaną parametru $\mathcal{A}$, co pozwala przypisać obserwowane różnice wyłącznie charakterowi losowości, a nie zmianom średniego tempa dyfuzji [37]. Porównanie przeprowadzono na podstawie rozkładów TAMSD, DMA oraz kurtozy przyrostów.

Na Rys. 3.5 przedstawiono rozkłady wartości TAMSD dla $\tau = 0.05$ dla różnych rozkładów losowego wykładnika dyfuzji. Największą zmienność obserwuje się dla rozkładu dwupunktowego, którego rozkład TAMSD charakteryzuje się bardzo szerokim rozstępem międzykwartylowym (IQR = 0.4669) oraz wysokim współczynnikiem zmienności (CV = 0.908). W porównaniu z rozkładem jednostajnym rozstęp międzykwartylowy jest większy o około 150%, przy jednocześnie znacznie niższej medianie (spadek o około 72%). Oznacza to, że choć średni wykładnik dyfuzji jest taki sam, realizacje odpowiadające rozkładowi dwupunktowemu generują zarówno bardzo małe, jak i bardzo duże wartości TAMSD.

Dla rozkładu jednostajnego obserwuje się wyraźnie mniejszy rozrzut wartości TAMSD (IQR = 0.1863, CV = 0.738) oraz najwyższą medianę spośród analizowanych przypadków. Rozkład beta zajmuje pozycję pośrednią, jego mediana jest nieco niższa niż dla rozkładu jednostajnego (spadek o około 12%), natomiast zmienność jest istotnie większa (IQR większy o około 61%). Wyniki te wskazują, że charakter losowości wykładnika dyfuzji w istotny sposób wpływa na stabilność estymatora TAMSD.

Analogiczne wnioski płyną z analizy zdetrendowanej średniej ruchomej, której rozkłady przedstawiono na Rys. 3.6. Również w tym przypadku największą zmienność obserwuje się dla rozkładu dwupunktowego, dla którego rozstęp międzykwartylowy wynosi 5.935 i jest większy o ponad 130% w porównaniu z rozkładem jednostajnym. Jednocześnie mediana DMA dla rozkładu dwupunktowego jest blisko o połowę mniejsza niż dla rozkładu jednostajnego.

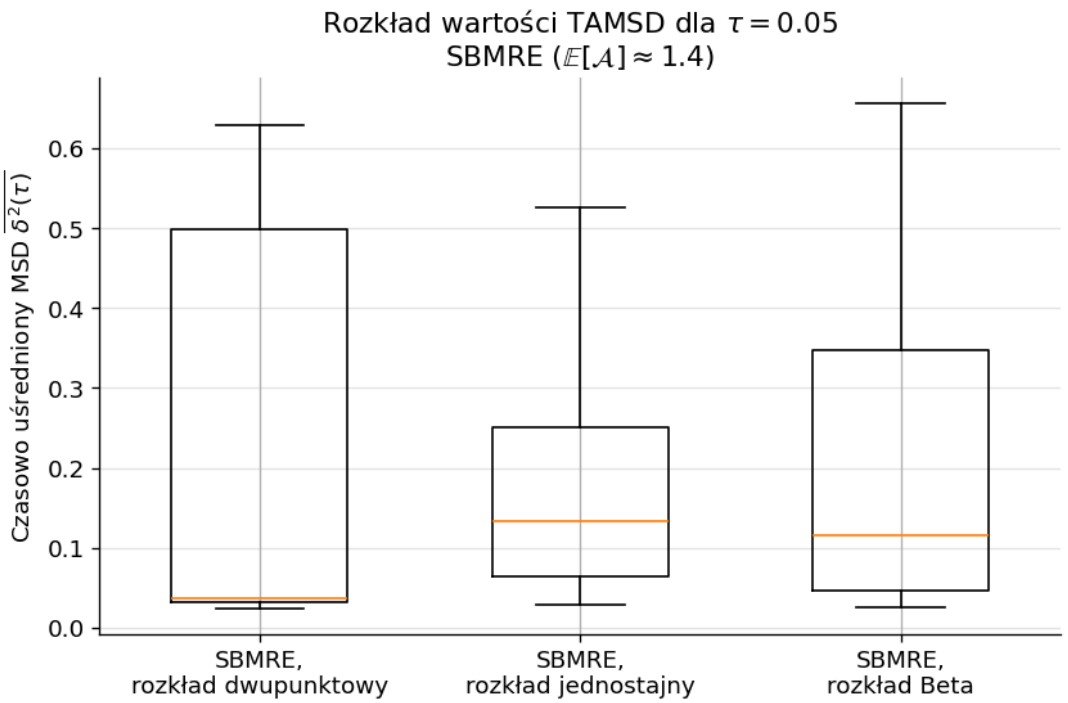

Rysunek 3.5: Rozkłady wartości TAMSD dla $\tau = 0.05$ dla procesu SBMRE przy różnych rozkładach losowego wykładnika dyfuzji $\mathcal{A}$.

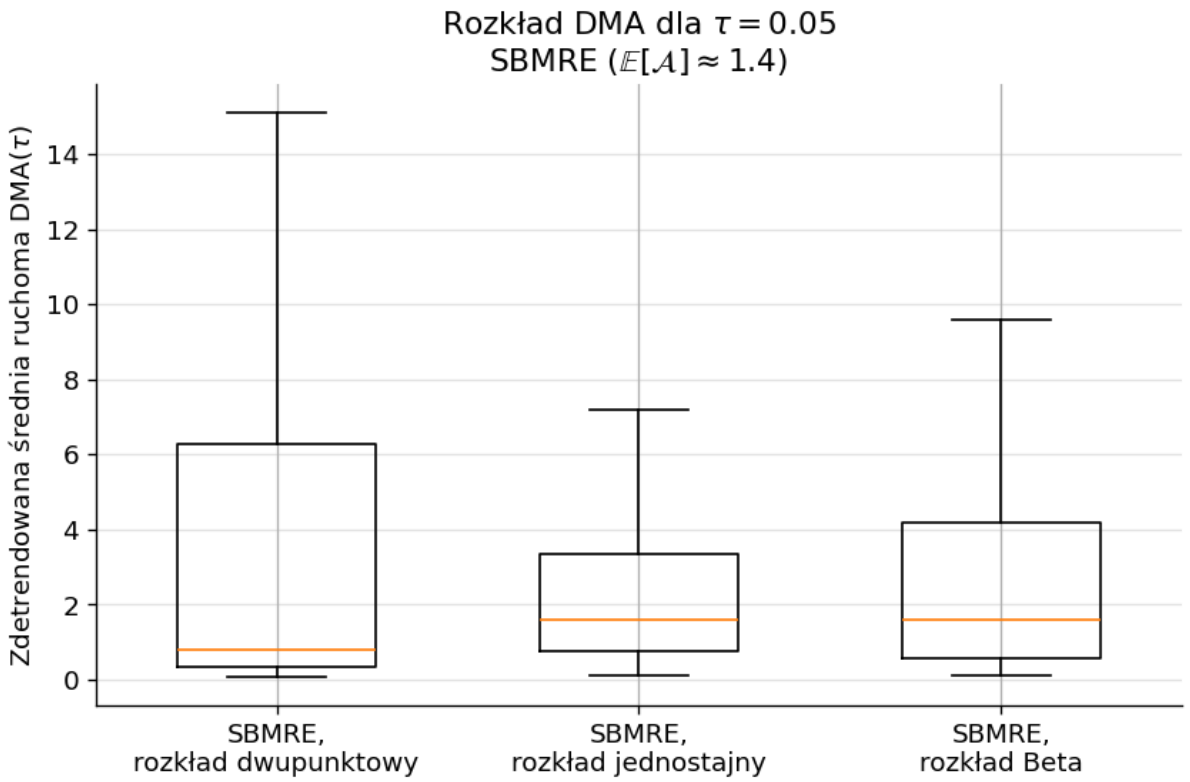

Rysunek 3.6: Rozkłady wartości DMA dla $\tau = 0.05$ dla procesu SBMRE przy różnych rozkładach losowego wykładnika dyfuzji $\mathcal{A}$.

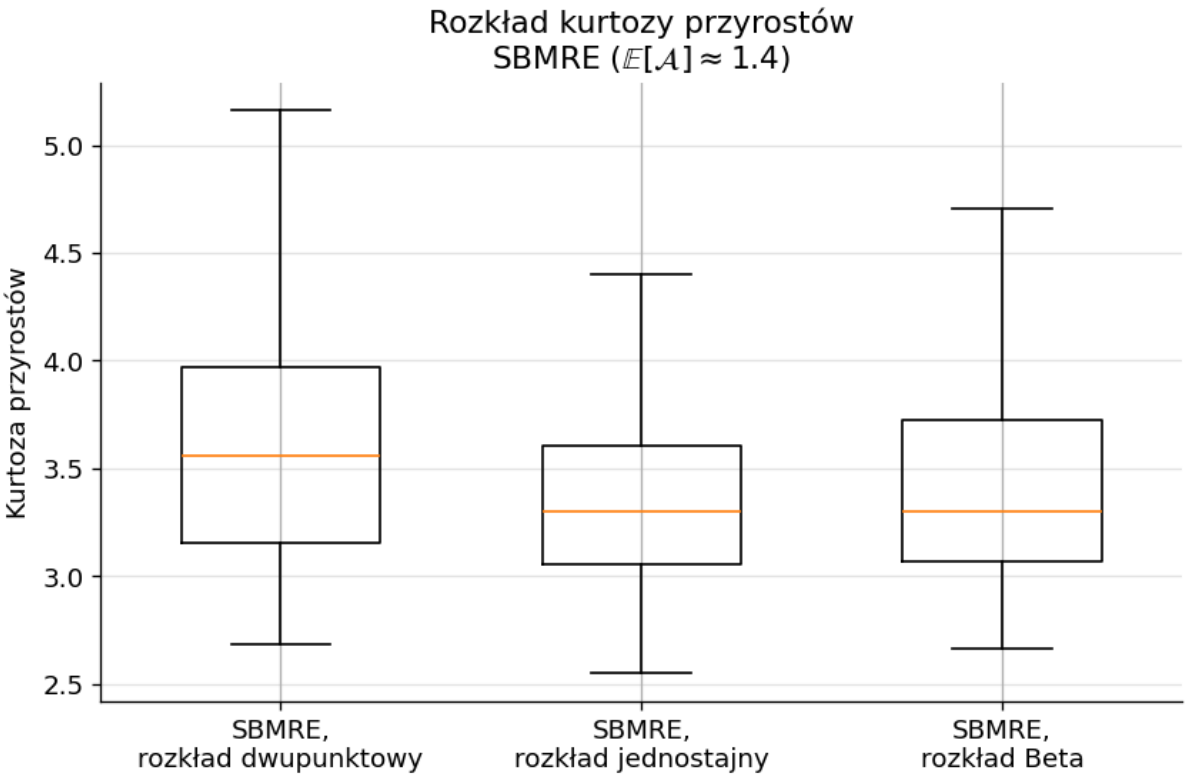

Rysunek 3.7: Rozkłady kurtozy przyrostów dla procesu SBMRE przy różnych rozkładach losowego wykładnika dyfuzji $\mathcal{A}$.

Rozkład jednostajny oraz beta charakteryzują się zbliżonymi wartościami median DMA, jednak rozkład beta wykazuje wyraźnie większą zmienność (IQR większy o około 41%). Potwierdza to obserwację, że bardziej skoncentrowane rozkłady parametru $\mathcal{A}$ prowadzą do większej heterogeniczności zachowania trajektorii, nawet przy zachowaniu tej samej wartości oczekiwanej wykładnika dyfuzji.

Uzupełnieniem analizy jest porównanie rozkładów kurtozy przyrostów, przedstawione na Rys. 3.7. W tym przypadku różnice pomiędzy rozkładami są mniej wyraźne niż dla TAMSD i DMA, jednak nadal zauważalne. Najwyższą medianę kurtozy obserwuje się dla rozkładu dwupunktowego (mediana 3.559), co odpowiada wzrostowi o około 8% względem rozkładu jednostajnego. Jednocześnie rozstęp międzykwartylowy jest w tym przypadku większy o blisko 50%, co wskazuje na częstsze występowanie realizacji o bardziej ekstremalnych przyrostach.

Dla rozkładu jednostajnego kurtoza przyrostów jest najbardziej stabilna (IQR = 0.5511), natomiast rozkład beta ponownie wykazuje zachowanie pośrednie, z umiarkowanie większym rozrzutem i medianą zbliżoną do przypadku jednostajnego. Wyniki te sugerują, że charakter losowości wykładnika dyfuzji wpływa nie tylko na skalę przemieszczeń, lecz także na strukturę rozkładu fluktuacji przyrostów.

Podsumowując, przeprowadzona analiza pokazuje, że w procesie SBMRE istotne znaczenie ma nie tylko sama obecność losowości wykładnika dyfuzji, lecz również jej charakter. Rozkład dwupunktowy prowadzi do największej zmienności analizowanych cech i najbardziej heterogenicznego zachowania trajektorii, natomiast rozkład jednostajny charakteryzuje się względnie największą stabilnością. Rozkład beta zajmuje pozycję pośrednią, łącząc cechy obu skrajnych przypadków. Wyniki te podkreślają, że przy interpretacji

własności procesów SBMRE oraz przy doborze cech do ich rozróżniania konieczne jest uwzględnienie nie tylko wartości oczekiwanej parametru dyfuzji, lecz również pełnego charakteru jego losowości.

3.4 Wpływ kroku czasowego

Kolejnym analizowanym aspektem danych symulowanych jest wpływ kroku czasowego Δt na stabilność obliczanych charakterystyk. Celem tej analizy jest sprawdzenie, czy uzyskane wyniki nie są artefaktem dyskretyzacji czasu, lecz odzwierciedlają rzeczywiste własności badanych procesów. W tym celu przeanalizowano wrażliwość wybranych statystyk na zmianę kroku czasowego, przy zachowaniu pozostałych parametrów symulacji na niezmienionym poziomie.

Analizę przeprowadzono dla kilku wartości kroku czasowego, przyjmując $\Delta t_{\min} = 0.001$ jako punkt odniesienia. Jako reprezentatywną cechę wybrano medianę wartości TAMSD dla ustalonego opóźnienia $\tau = 0.05$, zarówno dla procesu SBM, jak i dla procesu SBMRE z różnymi rozkładami losowego wykładnika dyfuzji.

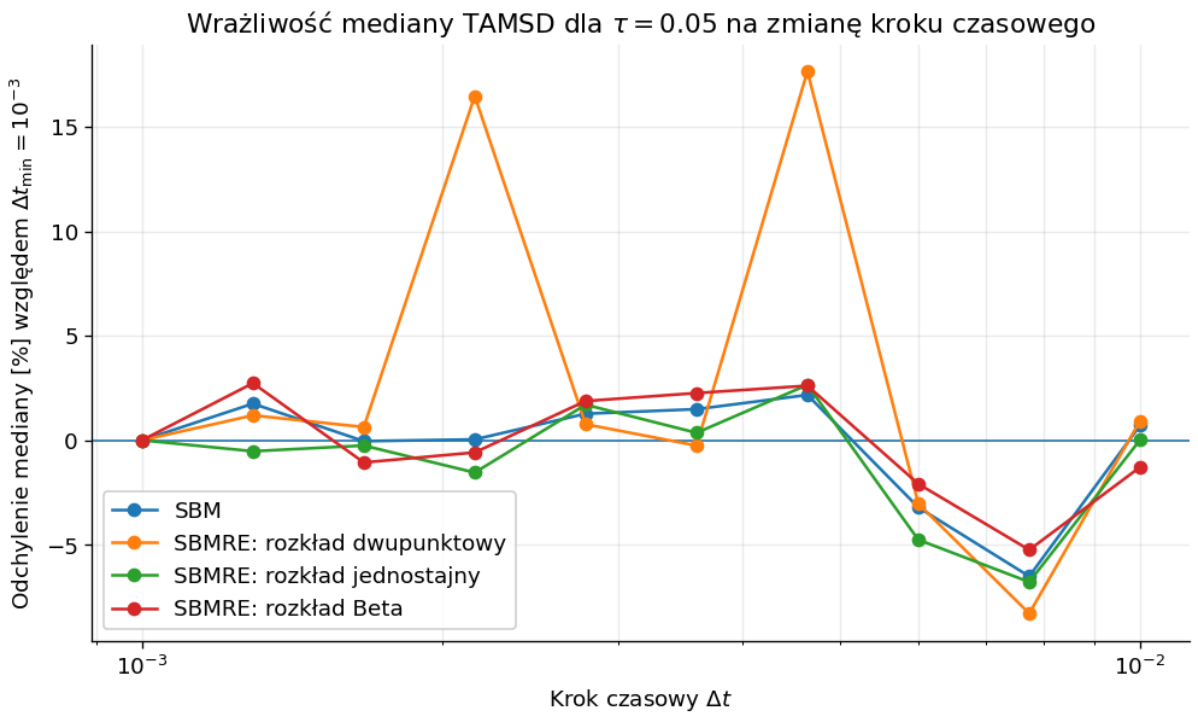

Rysunek 3.8: Względne odchylenie mediany TAMSD procesów SBM i SBMRE dla $\tau = 0.05$ w zależności od kroku czasowego Δt, odniesione do wartości dla $\Delta t_{\min} = 0.001$.

Na Rys. 3.8 przedstawiono względne odchylenia mediany TAMSD względem wartości uzyskanej dla najmniejszego kroku czasowego. Dla procesu SBM obserwowane odchylenia są niewielkie i nie przekraczają kilku procent, co wskazuje na wysoką stabilność estymatora TAMSD względem zmiany Δt. Podobne zachowanie widoczne jest dla procesu SBMRE z rozkładem jednostajnym oraz beta, dla których maksymalne względne odchylenia mediany TAMSD pozostają na poziomie kilku procent.

Największą wrażliwość na zmianę kroku czasowego wykazuje proces SBMRE z rozkładem dwupunktowym. W tym przypadku maksymalne względne odchylenie mediany

TAMSD jest wyraźnie większe niż dla pozostałych rozkładów. Zjawisko to wynika z samej natury rozkładu dwupunktowego, który generuje realizacje o skrajnie różnych wartościach parametru dyfuzji, co wzmacnia wpływ dyskretyzacji na estymowane statystyki. Pomimo tego, nawet w tym przypadku obserwowane odchylenia nie prowadzą do zmiany jakościowego charakteru rozkładów TAMSD.

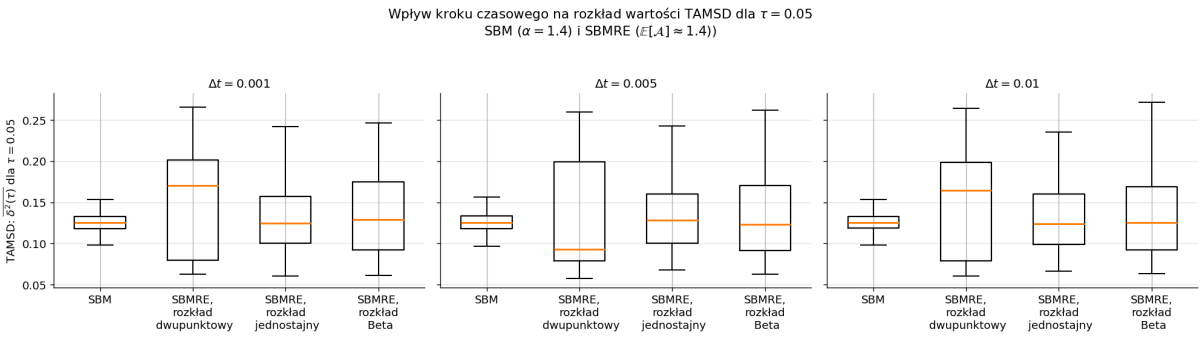

Rysunek 3.9: Rozkłady wartości TAMSD dla $\tau = 0.05$ dla różnych kroków czasowych Δt dla procesu SBM oraz SBMRE.

Uzupełnieniem powyższej analizy są rozkłady wartości TAMSD dla różnych kroków czasowych, przedstawione na Rys. 3.9. Porównanie boxplotów pokazuje, że zmiana kroku czasowego nie wpływa istotnie na położenie median ani na ogólny kształt rozkładów, zarówno dla procesu SBM, jak i dla poszczególnych wariantów SBMRE. Zachowane zostają charakterystyczne różnice pomiędzy procesami, obserwowane we wcześniejszych sekcjach.

Podsumowując, przeprowadzona analiza wskazuje, że obliczane charakterystyki, w szczególności mediana wartości TAMSD, są w dużej mierze odporne na zmianę kroku czasowego. Największą wrażliwość wykazuje proces SBMRE z rozkładem dwupunktowym, jednak nawet w tym przypadku obserwowane różnice mają charakter ilościowy, a nie jakościowy. Uzyskane wyniki potwierdzają, że wnioski formułowane na podstawie danych symulowanych nie są artefaktem dyskretyzacji czasu, lecz wynikają z rzeczywistych własności analizowanych procesów.

3.5 Podsumowanie

W niniejszym rozdziale przeprowadzono szczegółową analizę danych symulowanych w celu lepszego zrozumienia własności procesów SBM oraz SBMRE i czynników wpływających na zachowanie wybranych cech statystycznych. Analiza ta stanowiła uzupełnienie rozważań teoretycznych oraz pozwoliła na pogłębioną interpretację zachowania badanych modeli w różnych konfiguracjach parametrów.

W pierwszej kolejności zbadano wpływ długości trajektorii na własności procesów. Wykazano, że dla procesu SBM wydłużanie obserwacji prowadzi do stabilizacji analizowanych cech, w szczególności czasowo uśrednionego kwadratu przesunięcia oraz rozkładu przyrostów. W przypadku procesów SBMRE zaobserwowano natomiast utrzymywanie się, a nawet wzrost zmienności cech wraz z długością trajektorii, co wynika z losowego charakteru wykładnika dyfuzji i prowadzi do trajektoryjnej heterogeniczności realizacji.

Następnie przeanalizowano wpływ wartości wykładnika dyfuzji na dynamikę procesu SBM. Zarówno funkcja przesunięcia średniokwadratowego, jak i rozkłady TAMSD jednoznacznie odzwierciedlały przejście od subdyfuzji do superdyfuzji wraz ze wzrostem

parametru α. Wyniki te potwierdziły kluczową rolę wykładnika dyfuzji w kształtowaniu tempa rozprzestrzeniania się trajektorii oraz poziomu obserwowanych fluktuacji.

Kolejnym etapem analizy było porównanie różnych rodzajów losowości wykładnika dyfuzji w procesie SBMRE przy zachowaniu tej samej wartości oczekiwanej parametru. Wykazano, że charakter rozkładu losowego wykładnika istotnie wpływa na zmienność analizowanych cech. Największą heterogeniczność obserwowano dla rozkładu dwupunktowego, natomiast rozkład jednostajny charakteryzował się względnie największą stabilnością. Rozkład beta wykazywał zachowanie pośrednie pomiędzy tymi dwoma przypadkami.

Na końcu zbadano wpływ kroku czasowego na stabilność obliczanych charakterystyk. Przeprowadzona analiza wykazała, że zmiana kroku czasowego prowadzi jedynie do niewielkich, ilościowych odchyleń wartości cech, nie wpływając na ich jakościowe zachowanie ani na relacje pomiędzy analizowanymi procesami. Oznacza to, że uzyskane wyniki nie są artefaktem dyskretyzacji czasu, lecz wynikają z rzeczywistych własności badanych modeli.

Podsumowując, przeprowadzone analizy pokazują, że wybrane cechy statystyczne w sposób spójny i interpretowalny opisują dynamikę procesów SBM oraz SBMRE, a obserwowane różnice pomiędzy nimi są trwałe względem zmian podstawowych parametrów symulacji. Uzyskane wyniki potwierdzają zasadność zastosowanego podejścia symulacyjnego oraz pozwalają na wiarygodną interpretację własności badanych procesów w kontekście postawionych w pracy celów badawczych.

Podsumowanie

Celem niniejszej pracy było wykorzystanie metod uczenia maszynowego do klasyfikacji trajektorii skalowanego ruchu Browna ze stałym oraz losowym wykładnikiem anomalnej dyfuzji. W szczególności analizie poddano trajektorie generowane przez klasyczny model skalowanego ruchu Browna oraz jego uogólnienie z losowym wykładnikiem dyfuzji. Badania obejmowały symulacje numeryczne dla różnych scenariuszy rozkładów parametru anomalnej dyfuzji, zarówno w obszarze subdyfuzji, jak i superdyfuzji, a także ocenę skuteczności zaproponowanych metod klasyfikacji.

Przeprowadzone analizy wykazały, że trajektorie procesów SBM i SBMRE różnią się w sposób istotny pod względem wybranych czasowo uśrednionych statystyk, co umożliwia ich skuteczne rozróżnianie z wykorzystaniem algorytmów uczenia maszynowego. W szczególności wykazano, że losowa zmienność wykładnika dyfuzji w modelu SBMRE prowadzi do zwiększonej heterogeniczności trajektorii, co znajduje odzwierciedlenie w zachowaniu takich charakterystyk jak czasowo uśrednione przesunięcie średniokwadratowe oraz zdetrendowana średnia ruchoma.

Wyniki symulacji pokazały, że skuteczność klasyfikacji zależy od zakresu rozważanych parametrów oraz charakteru dynamiki procesu. W przypadku zawężonego zakresu parametrów anomalnej dyfuzji dokładność klasyfikacji była wyraźnie wyższa, co wskazuje, że ograniczenie przestrzeni parametrów ułatwia rozróżnianie modeli. Zaobserwowano również różnice pomiędzy przypadkami subdyfuzyjnymi i superdyfuzyjnymi, przy czym w niektórych scenariuszach losowość wykładnika dyfuzji stanowiła czynnik dominujący dla skuteczności metod klasyfikacyjnych.

Podsumowując, wyniki pracy potwierdzają, że połączenie symulacji numerycznych procesów stochastycznych z metodami uczenia maszynowego oraz cechami opartymi na czasowo uśrednionych statystykach stanowi efektywne narzędzie do identyfikacji modeli anomalnej dyfuzji z losowymi parametrami. Zaproponowane podejście umożliwia wychwycenie subtelnych różnic pomiędzy trajektoriami, które mogą być trudne do zauważenia przy zastosowaniu wyłącznie klasycznych metod analizy. Otrzymane rezultaty wskazują na potencjał praktycznych zastosowań prezentowanej metody w analizie danych trajektorii, w szczególności w kontekście identyfikacji procesów o złożonej i heterogenicznej dynamice.

Bibliografia

[1] Anderson, T. W., Darling, D. A. Asymptotic theory of certain goodness-of-fit criteria based on stochastic processes. *Annals of Mathematical Statistics 23*, 2 (1952), 193–212.

[2] Batchelor, G. K. Diffusion in a field of homogeneous turbulence: Ii. the relative motion of particles. *Mathematical Proceedings of the Cambridge Philosophical Society 48*, 2 (1952), 345–362.

[3] Beck, C., Cohen, E. G. D. Superstatistics. *Physica A 322* (2003), 267–275.

[4] Beran, J. *Statistics for Long-Memory Processes.* Chapman & Hall, 1994.

[5] Bishop, C. M. *Pattern Recognition and Machine Learning.* Springer, 2006.

[6] Bouchaud, J.-P., Georges, A. Anomalous diffusion in disordered media: Statistical mechanisms, models and physical applications. *Physics Reports 195*, 4–5 (1990), 127–293.

[7] Chubynsky, M. V., Slater, G. W. Diffusing diffusivity: a model for anomalous, yet brownian, diffusion. *Physical Review Letters 113*, 9 (2014), 098302.

[8] dos Santos, M., Colombo, E., Anteneodo, C. Random diffusivity scenarios behind anomalous non-gaussian diffusion. *Chaos, Solitons & Fractals 152*, C (None 2021), None.

[9] Ernst, D., Köhler, J., Weiss, M. Probing the type of anomalous diffusion with single-particle tracking. *Physical Chemistry Chemical Physics 16* (2014), 7686–7691.

[10] Fawcett, T. An introduction to roc analysis. *Pattern Recognition Letters 27*, 8 (2006), 861–874. ROC Analysis in Pattern Recognition.

[11] Goodfellow, I., Bengio, Y., Courville, A. *Deep Learning.* MIT Press, 2016. `http://www.deeplearningbook.org`.

[12] Hastie, T., Tibshirani, R., Friedman, J. *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*, 2 ed. Springer, 2009.

[13] Höfling, F., Franosch, T. Anomalous transport in the crowded world of biological cells. *Reports on Progress in Physics 76*, 4 (2013), 046602.

[14] Jarque, C. M., Bera, A. K. A test for normality of observations and regression residuals. *International Statistical Review 55*, 2 (1987), 163–172.

[15] Jeon, J.-H., Chechkin, A. V., Metzler, R. Scaled brownian motion: a paradoxical process with a time-dependent diffusivity for anomalous diffusion. *Physical Chemistry Chemical Physics 16*, 30 (2014), 15811–15817.

[16] Kingma, D. P., Ba, J. Adam: A method for stochastic optimization. *International Conference on Learning Representations* (2015).

[17] Kloeden, P. E., Platen, E. *Numerical Solution of Stochastic Differential Equations.* Stochastic Modelling and Applied Probability. Springer, 1992.

[18] Kohavi, R. A study of cross-validation and bootstrap for accuracy estimation and model selection. In *Proceedings of the 14th International Joint Conference on Artificial Intelligence (IJCAI)* (1995), pp. 1137–1143.

[19] Kolmogorov, A. N. Sulla determinazione empirica di una legge di distribuzione. *Giornale dell'Istituto Italiano degli Attuari 4* (1933), 83–91.

[20] Kolmogorov, A. N. Wienersche spiralen und einige andere interessante kurven im hilbertschen raum. *Doklady Akademii Nauk SSSR 26* (1940), 115–118.

[21] Krapf, D. Mechanisms underlying anomalous diffusion in the plasma membrane. *Current Topics in Membranes 75* (2015), 167–207.

[22] Krapf, D., Meroz, Y., Sokolov, I. M. Statistical test for anomalous diffusion based on empirical anomaly measure for gaussian processes. *Computational Statistics & Data Analysis 170* (2022), 107441.

[23] Lim, S. G., Muniandy, S. V. Self-similar gaussian processes for modeling anomalous diffusion. *Physical Review E 66*, 2 (2002), 021114.

[24] Magdziarz, M., Weron, K. Anomalous diffusion schemes underlying the cole–cole relaxation: The role of the inverse-time α-stable subordinator. *Physica A 367* (2006), 1–6.

[25] Mandelbrot, B. B., Van Ness, J. W. Fractional brownian motions, fractional noises and applications. *SIAM Review 10*, 4 (1968), 422–437.

[26] Maraj-Zygmąt, K., Grzesiek, A., Krapf, D., Wyłomańska, A. Statistical testing-based framework for differentiating anomalous diffusion models with constant and random parameters. *Journal of Computational and Applied Mathematics 472* (2026), 116801.

[27] Mazo, R. M. *Brownian Motion: Fluctuations, Dynamics, and Applications.* Oxford University Press, 2008.

[28] Metzler, R., Jeon, J.-H., Cherstvy, A. G., Barkai, E. Anomalous diffusion models and their properties: non-stationarity, non-ergodicity and ageing at the centenary of single particle tracking. *Physical Chemistry Chemical Physics 16*, 44 (2014), 24128–24164.

[29] Prechelt, L. Early stopping — but when? Tech. rep., Universität Karlsruhe, 1998.

[30] Safdari, H., Cherstvy, A. G., Chechkin, A. V., Sokolov, I. M., Metzler, R. Quantifying the non-ergodicity of scaled brownian motion. *Journal of Physics A: Mathematical and Theoretical 48*, 37 (2015), 375002.

[31] Schilling, R. L., Partzsch, L. *Brownian Motion: An Introduction to Stochastic Processes*. De Gruyter, 2012.

[32] Shapiro, S. S., Wilk, M. B. An analysis of variance test for normality. *Biometrika 52*, 3–4 (1965), 591–611.

[33] Smirnov, N. V. Table for estimating the goodness of fit of empirical distributions. *Annals of Mathematical Statistics 19*, 2 (1948), 279–281.

[34] Sposini, V., Chechkin, A. V., Seno, F., Pagnini, G., Metzler, R. Random diffusivity from stochastic equations: Comparison of two models for brownian yet non-gaussian diffusion. *New Journal of Physics 20*, 4 (2018), 043044.

[35] Thiel, F., Sokolov, I. M. Scaled brownian motion as a mean-field model for continuous-time random walks. *Physical Review E 89*, 1 (2014), 012115.

[36] Weiss, M. Single-particle tracking data reveal anticorrelated fractional brownian motion in crowded fluids. *Physical Review E 88*, 1 (2013), 010101.

[37] Woszczek, H., Chechkin, A., Wyłomańska, A. Scaled brownian motion with random anomalous diffusion exponent. *Communications in Nonlinear Science and Numerical Simulation 140* (2025), 108388.